PREPRINT — SOUMIS À ÉVALUATION PAR LES PAIRS

DCME, ECS et RAD

Trois Contributions Formelles pour la Gouvernance de l'IA Explicable

Mohamadou SIDIBE
Chief Data Officer, FGV
Fondateur, IA BIAIS INITIATIVE
contact@ia-biais-initiative.org
ORCID : [à compléter]

Catégorie arXiv	cs.AI (primaire), cs.LG, cs.CY
Mots-clés	XAI, explicabilité, gouvernance IA, dette algorithmique
DOI	10.5281/zenodo.23126471
Date	Octobre 2026
Version	1.0

Ce preprint présente le noyau original du framework AEXIA™.
Il constitue une contribution scientifique autonome, indépendante de la synthèse de référentiels.

Résumé

La gouvernance de l'intelligence artificielle explicable (XAI) souffre d'un déficit d'instruments de mesure et de pilotage. Les frameworks existants — NIST AI RMF, ISO/IEC 42001, MLTRL — fournissent des cadres de gestion des risques ou de maturité, mais aucun ne traite frontalement trois dimensions critiques : la décomposition causale multi-échelle des explications, la stabilité mesurable des explications, et la dette de responsabilité algorithmique accumulée par une organisation.

Cet article présente trois contributions originales :

1. **DCME** (*Dynamic Causal Multi-scale Explanation*) : une méthode d'explication qui décompose la prédiction d'un modèle en contributions causales organisées sur plusieurs échelles d'analyse, en distinguant les effets directs des effets médiés.
2. **ECS** (*Explanation Consistency Score*) : une métrique normalisée mesurant la stabilité locale d'une explication sous perturbation contrôlée du voisinage.
3. **RAD** (*Responsibility Algorithmic Debt*) : un indicateur cumulatif mesurant l'écart entre la maturité attendue et la maturité effective d'un système d'IA, pondéré par sa criticité réglementaire au sens de l'AI Act européen.

Nous formalisons chacun de ces concepts selon le standard scientifique (définition, formulation mathématique, conditions d'application, limites, positionnement, protocole de mesure) et proposons des protocoles de validation empirique sur des jeux de données publics (COMPAS, German Credit, Telco Churn). Ces contributions visent à combler une lacune identifiée dans la littérature et à fournir aux organisations des instruments opérationnels pour gouverner l'IA explicable de manière défendable.

Mots-clés : XAI, explicabilité, gouvernance IA, dette algorithmique, SHAP, LIME, causalité, AI Act.

DOI : `10.5281/zenodo.23126471`

Table des matières

Résumé **1**

1 Introduction **4**
1.1 Contexte . . . 4
1.2 Contributions . . . 4
1.3 Structure de l'article . . . 4

2 Travaux connexes **4**
2.1 Méthodes d'explication locale . . . 4
2.2 Métriques d'évaluation des explications . . . 4
2.3 Modèles de maturité . . . 5
2.4 Dette technique . . . 5

3 DCME : Dynamic Causal Multi-scale Explanation **5**
3.1 Définition formelle . . . 5
3.2 Contrainte d'additivité multi-échelle . . . 5
3.3 Conditions d'application . . . 5
3.4 Limites connues . . . 6
3.5 Positionnement vs existant . . . 6
3.6 Protocole de mesure . . . 6
3.7 Cas d'application proposé . . . 6

4 ECS : Explanation Consistency Score **6**
4.1 Définition formelle . . . 6
4.2 Propriétés . . . 7
4.3 Conditions d'application . . . 7
4.4 Limites connues . . . 7
4.5 Positionnement vs existant . . . 7
4.6 Protocole de mesure . . . 7
4.7 Cas d'application proposé . . . 8

5 RAD : Responsibility Algorithmic Debt **8**
5.1 Définition formelle . . . 8
5.2 Interprétation . . . 8
5.3 Conditions d'application . . . 8
5.4 Limites connues . . . 8
5.5 Positionnement vs existant . . . 9
5.6 Protocole de mesure . . . 9
5.7 Cas d'application proposé . . . 9

6 Articulation des trois concepts **9**

7 Protocole de validation empirique **10**
7.1 Jeux de données . . . 10
7.2 Modèles . . . 10
7.3 Métriques comparées . . . 10
7.4 Résultats attendus . . . 10

8 Discussion **10**
8.1 Contributions théoriques 10
8.2 Limites générales 10
8.3 Perspectives 10

9 Conclusion **11**

1 Introduction

1.1 Contexte

L'intelligence artificielle est au cœur de décisions à fort impact : scoring de crédit, recrutement, diagnostic médical, justice prédictive, tarification. L'AI Act européen (Règlement UE 2024/1689) impose des obligations de transparence et d'explicabilité pour les systèmes à haut risque à compter du 2 décembre 2027 (après report par le règlement Digital Omnibus UE 2026/1744). Le RGPD (article 22) exige déjà un droit à l'explication pour toute décision automatisée produisant des effets juridiques.

Pourtant, les organisations ne disposent pas d'instruments de mesure suffisants pour évaluer, piloter et améliorer leur gouvernance XAI. Les frameworks existants fournissent des cadres conceptuels mais restent silencieux sur trois questions opérationnelles :

— Comment décomposer causalement une explication multi-échelle ?

— Comment mesurer objectivement la stabilité d'une explication ?

— Comment quantifier la dette de responsabilité algorithmique accumulée ?

1.2 Contributions

Cet article présente trois contributions originales :

DCME Une méthode d'explication causale multi-échelle qui généralise SHAP en intégrant les effets médiés et les échelles d'analyse (Section 3).

ECS Une métrique normalisée de stabilité des explications, comparable entre méthodes (Section 4).

RAD Un indicateur cumulatif de dette de responsabilité algorithmique, première formalisation du concept (Section 5).

1.3 Structure de l'article

La Section 2 présente les travaux connexes. La Section 3 formalise DCME. La Section 4 formalise ECS. La Section 5 formalise RAD. La Section 6 discute l'articulation des trois concepts. La Section 7 propose des protocoles de validation empirique. La Section 8 discute les limites et perspectives. La Section 9 conclut.

2 Travaux connexes

2.1 Méthodes d'explication locale

SHAP [7] fournit une décomposition additive basée sur les valeurs de Shapley [13]. LIME [11] approxime localement un modèle complexe par un modèle linéaire. Integrated Gradients [14] attribue les contributions par intégration des gradients. ANCHORS [12] produit des règles suffisantes. DiCE [8] génère des contrefactuels.

Ces méthodes produisent des explications à une échelle unique, sans distinguer les effets directs des effets médiés.

2.2 Métriques d'évaluation des explications

Alvarez-Melis & Jaakkola [1] proposent une mesure de robustesse sous bruit. Yeh et al. [15] introduisent les notions de fidélité et de sensibilité. Fidelity (LIME) mesure la fidélité locale. Ces métriques ne sont pas normalisées et ne sont pas directement comparables entre méthodes.

2.3 Modèles de maturité

Le MLTRL [6] propose une échelle de maturité à 9 niveaux pour les systèmes ML. Le CMMI [2] fournit un modèle de maturité à 5 niveaux pour les processus. Le DCAM [4] évalue les capacités de gestion des données. Aucun ne traite la dette de responsabilité algorithmique.

2.4 Dette technique

Cunningham [3] introduit la notion de dette technique. Les travaux ultérieurs ont étendu ce concept à la dette de données et à la dette de modèles. Aucun travail n'a formalisé la dette de responsabilité algorithmique.

3 DCME : Dynamic Causal Multi-scale Explanation

3.1 Définition formelle

Définition 1 (DCME)**.** *Soit $f : \mathcal{X} \to \mathcal{Y}$ un modèle prédictif, $x \in \mathcal{X}$ une instance, et $\hat{y} = f(x)$ la prédiction. La **Décomposition Causale Multi-Échelle** (DCME) est la décomposition :*

$$\hat{y} = \phi_0 + \sum_{s \in \mathcal{S}} \sum_{i \in \mathcal{F}_s} \phi_i^{(s)} + \sum_{(i,j) \in \mathcal{E}} \psi_{ij} \tag{1}$$

où :

- $\phi_0 \in \mathbb{R}$ *est la prédiction de base (baseline),*
- $\mathcal{S} = \{s_1, \ldots, s_K\}$ *est un ensemble fini d'échelles d'analyse,*
- $\mathcal{F}_s$ *est l'ensemble des variables à l'échelle s,*
- $\phi_i^{(s)} \in \mathbb{R}$ *est la contribution directe de la variable i à l'échelle s,*
- $\mathcal{E} \subseteq \mathcal{F} \times \mathcal{F}$ *est l'ensemble des effets causaux médiés,*
- $\psi_{ij} \in \mathbb{R}$ *est l'effet médié de la variable i sur la variable j.*

3.2 Contrainte d'additivité multi-échelle

Propriété 1 (Additivité)**.** *La décomposition DCME satisfait la contrainte :*

$$\sum_{s \in \mathcal{S}} \sum_{i \in \mathcal{F}_s} \phi_i^{(s)} + \sum_{(i,j) \in \mathcal{E}} \psi_{ij} = \hat{y} - \phi_0 \tag{2}$$

Cette contrainte garantit la cohérence globale de l'explication.

3.3 Conditions d'application

- Le modèle f est différentiable ou approximable localement ;
- Le graphe causal $\mathcal{G} = (\mathcal{F}, \mathcal{E})$ est connu ou inférable ;
- Les données sont stationnaires sur la fenêtre d'analyse ;
- L'absence de variables latentes non observables majeures est vérifiée.

3.4 Limites connues

Limite 1 (Complexité computationnelle)**.** *La complexité de DCME est $O(K \cdot |\mathcal{F}|^2)$ pour K échelles et $|\mathcal{F}|$ variables.*

Limite 2 (Dépendance au graphe causal)**.** *Un graphe causal mal spécifié produit des contributions ψ_{ij} biaisées.*

Limite 3 (Variables latentes)**.** *DCME ne traite pas les variables latentes ni les confusions non observées.*

3.5 Positionnement vs existant

Méthode	Échelle	Causalité	Médiation	Complexité
SHAP	Unique (additive)	Non	Non	$O(2^n)$ exact
LIME	Locale (linéaire)	Non	Non	$O(n)$ par instance
Integrated Gradients	Unique (gradient)	Non	Non	$O(n)$ par instance
ANCHORS	Locale (règles)	Non	Non	$O(n \log n)$
DCME	**Multi-échelle**	**Oui**	**Oui**	$O(K \cdot \|\mathcal{F}\|^2)$

3.6 Protocole de mesure

1. **Construction du graphe causal** : expertise métier + tests statistiques (Granger, PC algorithm).
2. **Définition des échelles** : macro (système), méso (sous-système), micro (variable).
3. **Estimation des contributions directes** : méthode d'attribution adaptée à chaque échelle (SHAP, coefficient de régression, etc.).
4. **Estimation des effets médiés** : propagation sur le graphe via les formules de Pearl [9].
5. **Vérification de l'additivité** : $\sum \phi_i^{(s)} + \sum \psi_{ij} = \hat{y} - \phi_0$.
6. **Validation croisée** : comparaison avec SHAP sur les variables non médiées.
7. **Tests de robustesse** : variation des échelles, du graphe, des données.

3.7 Cas d'application proposé

Application sur :

— **COMPAS** [10] : décomposition multi-échelle (macro : profil socio-économique ; méso : historique judiciaire ; micro : variable individuelle) et effets médiés (race → quartier → décision).

— **German Credit** [5] : comparaison avec SHAP sur les variables non médiées.

4 ECS : Explanation Consistency Score

4.1 Définition formelle

Définition 2 (ECS)**.** *Soit f un modèle, $\phi(f, x)$ l'explication de f sur l'instance x, et $\mathcal{N}_\epsilon(x)$ un voisinage de x de rayon ϵ. L'**Explanation Consistency Score** est défini par :*

$$ECS(f, x, \epsilon) = 1 - \frac{1}{N} \sum_{k=1}^{N} \frac{\|\phi(f, x) - \phi(f, x_k)\|_1}{\|\phi(f, x)\|_1 + \delta} \tag{3}$$

où $x_k \sim \mathcal{N}_\epsilon(x)$ sont N échantillons voisins, $\|\cdot\|_1$ est la norme L1, et $\delta > 0$ est une constante de régularisation.

4.2 Propriétés

Propriété 2 (Bornes)**.** *$ECS(f, x, \epsilon) \in [0, 1]$ pour tout x, ϵ.*

Propriété 3 (Stabilité parfaite)**.** *$ECS(f, x, \epsilon) = 1$ si et seulement si $\phi(f, x) = \phi(f, x_k)$ pour tout $x_k \in \mathcal{N}_\epsilon(x)$.*

Propriété 4 (Version agrégée)**.** *La version agrégée au niveau du modèle est :*

$$ECS_{model}(f, \mathcal{D}, \epsilon) = \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} ECS(f, x, \epsilon) \tag{4}$$

4.3 Conditions d'application

— Méthode d'explication déterministe ou à variance contrôlée ;
— Échantillonnage bien défini du voisinage (gaussien, uniforme) ;
— Normalisation des variables avant calcul ;
— Choix justifié de ϵ (recommandé : 5 % de l'écart-type par variable).

4.4 Limites connues

Limite 4 (Stabilité ≠ fidélité)**.** *ECS mesure la stabilité, pas la fidélité. Une explication stable peut être stable et fausse.*

Limite 5 (Sensibilité à ϵ)**.** *Le choix de ϵ doit être documenté systématiquement.*

Limite 6 (Coût computationnel)**.** *N recalculs d'explication par instance.*

4.5 Positionnement vs existant

Métrique	Mesure	Stabilité	Fidélité
Fidelity (LIME)	Fidélité locale	Non	Oui
Robustness [1]	Stabilité sous bruit	Oui	Non
Sensitivity [15]	Variation de l'explication	Oui	Non
ECS	**Stabilité normalisée**	**Oui**	Non

4.6 Protocole de mesure

1. Choix de ϵ : 5 % de l'écart-type par variable (recommandé).
2. Choix de N : 100 échantillons par instance.
3. Génération du voisinage gaussien multivarié centré sur x.
4. Calcul de $\phi(f, x)$ et de $\phi(f, x_k)$ pour chaque k.
5. Calcul de $\text{ECS}(f, x, \epsilon)$.
6. Agrégation au niveau du modèle : ECS_{model}.
7. Interprétation :
   — $\text{ECS} \geq 0.80$: stable, validable ;
   — $0.50 \leq \text{ECS} < 0.80$: stabilité modérée, à surveiller ;
   — $\text{ECS} < 0.50$: instabilité, incident à ouvrir.

4.7 Cas d'application proposé

Application sur :

— Un modèle XGBoost de churn (données publiques Telco Churn).

— Un modèle de scoring crédit (German Credit).

— Comparaison SHAP / LIME / DCME via ECS sur le même jeu.

5 RAD : Responsibility Algorithmic Debt

5.1 Définition formelle

Définition 3 (RAD)**.** *Soit un portefeuille de N systèmes d'IA. Pour chaque système i, soit $S^{(i)}_{attendu}(t)$ le niveau de maturité cible à l'instant t, $S^{(i)}_{effectif}(t)$ le niveau effectif, et $\beta_i \in \{1,2,3,4\}$ le coefficient de criticité réglementaire au sens de l'AI Act. Le* ***Responsibility Algorithmic Debt*** *du système i sur un horizon T est défini par :*

$$RAD_i(T) = \sum_{t=1}^{T} \alpha_t \cdot \max\left(0, S^{(i)}_{attendu}(t) - S^{(i)}_{effectif}(t)\right) \cdot \beta_i \tag{5}$$

où $\alpha_t = e^{-\lambda(T-t)}$ est un facteur de récence avec $\lambda \approx 0.1/mois$.

Définition 4 (RAD portefeuille)**.** *Le RAD du portefeuille est la somme des RAD par système :*

$$RAD_{portfolio}(T) = \sum_{i=1}^{N} RAD_i(T) \tag{6}$$

Définition 5 (RAD normalisé)**.** *Le RAD normalisé, pour comparaison inter-organisations, est :*

$$RAD_{norm}(T) = \frac{RAD_{portfolio}(T)}{N \cdot \beta_{max} \cdot S_{max}} \tag{7}$$

où $S_{max} = 9$ et $\beta_{max} = 4$.

5.2 Interprétation

— $\text{RAD}_{norm} < 0.10$: organisation alignée ;

— $0.10 \leq \text{RAD}_{norm} < 0.25$: écarts modérés, plan d'amélioration recommandé ;

— $\text{RAD}_{norm} \geq 0.25$: dette critique, arbitrage budgétaire nécessaire.

5.3 Conditions d'application

— Historisation régulière des niveaux MLTRL ou équivalents (au moins trimestrielle) ;

— Classification AI Act stable pour chaque système ;

— Cibles $S_{attendu}$ définies dans la roadmap de gouvernance ;

— Horizon $T \geq 6$ mois pour un RAD significatif.

5.4 Limites connues

Limite 7 (Dépendance à la discipline de mesure)**.** *Un RAD calculé sur des données parcellaires est peu fiable.*

Limite 8 (Risques émergents)**.** *RAD ne capture pas les risques émergents non encore réglementés.*

Limite 9 (Comparaison inter-organisations)**.** *La comparaison est délicate si les classifications AI Act diffèrent.*

5.5 Positionnement vs existant

Concept	Domaine	Nature
Technical Debt [3]	Développement logiciel	Dette de code
Data Debt	Gouvernance des données	Dette de qualité
Model Debt	MLOps	Dette de maintenance
AI Risk Score (NIST AI RMF)	Gestion des risques	Risque instantané
RAD	**Responsabilité algorithmique**	**Dette cumulée**

5.6 Protocole de mesure

1. Définir les cibles $S^{(i)}_{attendu}(t)$ pour chaque système (roadmap de gouvernance).
2. Mesurer $S^{(i)}_{effectif}(t)$ selon le protocole MLTRL ou équivalent.
3. Historiser dans un entrepôt temporel.
4. Calculer $\text{RAD}_i(t)$ mensuellement.
5. Agréger au niveau portefeuille : $\text{RAD}_{portfolio}(T)$.
6. Normaliser : $\text{RAD}_{norm}(T)$.
7. Interpréter selon les seuils définis.

5.7 Cas d'application proposé

Application sur :

— Un portefeuille de 20 systèmes d'IA d'une organisation fictive ou anonymisée ;

— Simulation sur 24 mois avec ou sans plan d'amélioration ;

— Démonstration de l'impact d'un investissement en gouvernance XAI sur le RAD.

6 Articulation des trois concepts

Les trois concepts sont interdépendants :

— DCME produit des explications plus riches mais potentiellement moins stables — la stabilité est mesurée par ECS.

— ECS évalue la qualité opérationnelle des explications produites par DCME, SHAP ou LIME.

— RAD intègre les niveaux de maturité, eux-mêmes dépendants de la qualité des explications mesurée par DCME + ECS.

Concept	Pilier AEXIA	Niveau requis	Usage opérationnel
DCME	F (Fondements)	N4 — Avancé	Explication causale multi-échelle
ECS	M (Mesure)	N4 — Avancé	Évaluation de la stabilité des explications
RAD	G (Gouvernance)	N4 — Avancé	Pilotage de la dette de responsabilité algorithmique

7 Protocole de validation empirique

7.1 Jeux de données

— **COMPAS** : prédiction de récidive, sensible aux biais raciaux.
— **German Credit** : scoring crédit, sensible aux biais socio-économiques.
— **Telco Churn** : prédiction d'attrition, sensible aux biais de segmentation.

7.2 Modèles

— XGBoost (arbres boostés) ;
— Régression logistique (modèle linéaire de référence) ;
— Réseau de neurones multicouche (modèle non linéaire).

7.3 Métriques comparées

— SHAP, LIME, DCME pour l'explication ;
— ECS, Fidelity, Robustness, Sensitivity pour la qualité des explications ;
— RAD pour la dette de responsabilité algorithmique.

7.4 Résultats attendus

— DCME produit des explications plus riches que SHAP mais avec un ECS plus faible.
— ECS discrimine les méthodes d'explication de manière reproductible.
— RAD évolue de manière cohérente avec l'investissement en gouvernance.

8 Discussion

8.1 Contributions théoriques

Cet article formalise trois concepts originaux :

— DCME étend SHAP à la causalité multi-échelle ;
— ECS normalise la mesure de stabilité des explications ;
— RAD est, à notre connaissance, la première formalisation de la dette de responsabilité algorithmique.

8.2 Limites générales

— La validation empirique reste à réaliser sur les jeux de données proposés ;
— Les concepts sont conçus pour le contexte réglementaire européen (AI Act, RGPD) ;
— DCME et RAD nécessitent un niveau de maturité organisationnelle N4.

8.3 Perspectives

— Implémentation open source (`dcmc-py`, `ecs-py`, `rad-py`) ;
— Étude de cas industrielle (FGV ou partenaire) ;
— Contribution à la normalisation ISO/IEC JTC 1/SC 42.

9 Conclusion

Cet article a présenté trois contributions originales pour la gouvernance de l'IA explicable : DCME, ECS et RAD. Chacune répond à une lacune identifiée dans la littérature et fournit un instrument opérationnel, mesurable et défendable. Les travaux futurs porteront sur la validation empirique, l'implémentation open source et l'ancrage institutionnel.

Disponibilité des données et du code : le code sera publié sous licence Apache 2.0 sur GitHub (`ia-biais-initiative/dcmc-py`, `ecs-py`, `rad-py`) après acceptation.

Conflits d'intérêts : l'auteur déclare ne pas avoir de conflit d'intérêts.

Financement : ce travail n'a reçu aucun financement spécifique.

Références

[1] Alvarez-Melis, D., & Jaakkola, T. S. (2018). On the Robustness of Interpretability Methods. *ICML Workshop on Human Interpretability*.

[2] CMMI Institute (2018). *CMMI for Development, Version 2.0*.

[3] Cunningham, W. (1992). The WyCash Portfolio Management System. *OOPSLA*.

[4] EDM Council (2019). *DCAM — Data Management Capability Assessment Model*.

[5] Hofmann, H. (1994). Statlog (German Credit Data). UCI Machine Learning Repository.

[6] Lavin, A., Gilligan-Lee, C. M., Visnjic, A., et al. (2022). Technology readiness levels for machine learning systems. *Nature Communications*, 13(1), 6039.

[7] Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS*.

[8] Mothilal, R. K., Sharma, A., & Tan, C. (2020). Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations. *FAccT*.

[9] Pearl, J. (2009). *Causality : Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

[10] ProPublica (2016). COMPAS Recidivism Risk Score Analysis.

[11] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You ?" : Explaining the Predictions of Any Classifier. *KDD*.

[12] Ribeiro, M. T., Singh, S., & Guestrin, C. (2018). Anchors : High-Precision Model-Agnostic Explanations. *AAAI*.

[13] Shapley, L. S. (1953). A Value for n-Person Games. *Contributions to the Theory of Games*, 2, 307-317.

[14] Sundararajan, M., Taly, A., & Yan, Q. (2017). Axiomatic Attribution for Deep Networks. *ICML*.

[15] Yeh, C.-K., Hsieh, C.-Y., Suggala, A., Inouye, D. I., & Ravikumar, P. (2019). On the (In)fidelity and Sensitivity of Explanations. *NeurIPS*.

[16] Règlement (UE) 2024/1689 du Parlement européen et du Conseil (AI Act).

[17] Règlement (UE) 2026/1744 dit « Digital Omnibus ».