AEXIA™

Fiches pédagogiques

DCME · ECS · RAD expliqués à tous les niveaux

Comprendre, expliquer et défendre le noyau original du framework AEXIA™

Avec exercices et corrections détaillées

Mohamadou SIDIBE

Chief Data Officer · Expert en Gouvernance des Données & IA

Polytechnique ExED 2026

Fondateur, IA BIAIS INITIATIVE

contact@ia-biais-initiative.org

Version : 1.0 · Octobre 2026

Licence : CC BY 4.0

DOI : 10.5281/zenodo.23126471

Ce livret est conçu pour être utilisé en formation, en soutenance,
en pédagogie ou en vulgarisation scientifique.

Table des matières

Avant-propos **iii**

I Fiches pédagogiques **1**

1 DCME — Décomposition Causale Multi-Échelle **2**
1.1 L'analogie du quotidien . . . 2
1.2 Exemple concret . . . 2
1.3 La formule expliquée mot par mot . . . 3
1.4 Démonstration intuitive . . . 3
1.5 Objections fréquentes . . . 4
1.6 Trois niveaux d'explication . . . 4
1.7 Points clés . . . 4

2 ECS — Score de Cohérence des Explications **5**
2.1 L'analogie du quotidien . . . 5
2.2 Exemple concret . . . 5
2.3 La formule expliquée mot par mot . . . 6
2.4 Démonstration intuitive . . . 6
2.5 Interprétation . . . 6
2.6 Objections fréquentes . . . 7
2.7 Trois niveaux d'explication . . . 7
2.8 Points clés . . . 7

3 RAD — Dette de Responsabilité Algorithmique **8**
3.1 L'analogie du quotidien . . . 8
3.2 Exemple concret . . . 8
3.3 La formule expliquée mot par mot . . . 9
3.4 Interprétation . . . 9
3.5 Objections fréquentes . . . 9
3.6 Trois niveaux d'explication . . . 10
3.7 Points clés . . . 10

4 Synthèse transversale **11**
4.1 Comment articuler les trois concepts ? . . . 11
4.2 Comment défendre ces concepts . . . 11

II Exercices et corrections **12**

5 Exercices — DCME **13**
5.1 Exercice 1 — Identifier les niveaux d'analyse (facile) . . . 13
5.2 Exercice 2 — Distinguer effet direct et effet médié (moyen) . . . 14
5.3 Exercice 3 — Appliquer la formule DCME (difficile) . . . 14

6 Exercices — ECS **16**
6.1 Exercice 4 — Calculer un ECS simple (facile) 16
6.2 Exercice 5 — Comparer deux méthodes (moyen) 17
6.3 Exercice 6 — Détecter une instabilité (difficile) 18

7 Exercices — RAD **19**
7.1 Exercice 7 — Calculer un RAD simple (facile) 19
7.2 Exercice 8 — RAD normalisé (moyen) 20
7.3 Exercice 9 — Priorisation par RAD (difficile) 20

8 Exercices transversaux **22**
8.1 Exercice 10 — Choisir la bonne méthode (moyen) 22
8.2 Exercice 11 — Étude de cas complète (difficile) 23
8.3 Exercice 12 — Défense en soutenance (difficile) 25

III Annexes **26**

9 Glossaire **27**

10 Références **28**

À propos de l'auteur **29**

Avant-propos

Ce livret a été conçu pour répondre à une question simple : **comment expliquer et défendre trois concepts mathématiques complexes à n'importe quel public ?**

Les trois concepts présentés — DCME, ECS et RAD — constituent le **noyau original du framework AEXIA™**. Ils sont publiés, citables et défendables devant un comité scientifique. Mais un concept publié qui n'est pas compris par les équipes opérationnelles reste un concept mort.

Ce livret vise à combler cet écart. Chaque concept est présenté selon **sept angles complémentaires** :

1. **L'idée en une phrase** — pour la mémoire immédiate
2. **L'analogie du quotidien** — pour l'ancrage intuitif
3. **L'exemple concret** — pour la démonstration pratique
4. **La formule expliquée mot par mot** — pour la rigueur mathématique
5. **Les objections fréquentes** — pour la défense argumentée
6. **Trois niveaux d'explication** — enfant, dirigeant, chercheur
7. **Des exercices progressifs** — pour l'appropriation active

Conseil d'utilisation — Ce livret peut se lire de trois manières :

— **Linéaire** — pour une compréhension complète

— **Par fiche** — pour approfondir un concept spécifique

— **Par exercice** — pour un usage en formation ou en atelier

Première partie

Fiches pédagogiques

DCME — Décomposition Causale Multi-Échelle

Idée clé

DCME explique une décision d'IA en distinguant ce qui agit directement, ce qui agit indirectement, et à quel niveau de profondeur.

1.1 L'analogie du quotidien

Analogie du quotidien

Imaginez que vous êtes médecin et qu'un patient vous dit : « J'ai mal à la tête. »
Niveau 1 — Explication directe : « Vous avez mal parce que vous avez de la fièvre. »
Niveau 2 — Explication indirecte : « Vous avez de la fièvre parce que vous avez la grippe. La grippe cause la fièvre, qui cause le mal de tête. »
Niveau 3 — Explication multi-échelle :

— **Échelle individuelle (micro)** : votre système immunitaire réagit au virus.

— **Échelle domestique (méso)** : votre enfant a ramené le virus de l'école.

— **Échelle sociétale (macro)** : une épidémie saisonnière circule dans la région.

DCME fait exactement cela avec les décisions d'IA : il décompose une prédiction en distinguant les niveaux et les chemins de causalité.

1.2 Exemple concret

Contexte : une banque refuse un prêt. Le modèle d'IA est complexe (XGBoost). On veut expliquer *pourquoi*.

Donnée client	Valeur
Âge	35 ans
Revenu	2 500 €/mois
Code postal	93 (Seine-Saint-Denis)
Historique crédit	2 retards de paiement
Décision	**Refus**

Explication SHAP classique

« Code postal : −15 % · Revenus : −20 % · Retards : −40 % »

Une liste de contributions. Utile, mais incomplète.

Explication DCME

Échelle	Contribution directe	Effet médié
Micro (variable)	Historique : −40 %	—
Méso (contexte)	Code postal : −15 %	Revenus → Code postal → Refus : −8 %
Macro (système)	—	Historique scolaire → Revenus → Refus : −12 %

Résultat : DCME révèle que le code postal n'agit pas seulement directement, mais aussi *par l'intermédiaire des revenus*, qui dépendent eux-mêmes du parcours scolaire. C'est un **effet médié**.

1.3 La formule expliquée mot par mot

Formule expliquée

$$\hat{y} = \phi_0 + \sum_{s \in \mathcal{S}} \sum_{i \in \mathcal{F}_s} \phi_i^{(s)} + \sum_{(i,j) \in \mathcal{E}} \psi_{ij} \tag{1.1}$$

Symbole	Signification	Analogie
$\hat{y}$	La prédiction du modèle	Le total d'une facture
ϕ_0	La prédiction de base (moyenne)	Le prix de départ
$\mathcal{S}$	L'ensemble des échelles	Niveaux micro, méso, macro
$\mathcal{F}_s$	Les variables à l'échelle s	Les ingrédients par niveau
$\phi_i^{(s)}$	Contribution directe de i à l'échelle s	Ce que chaque ingrédient ajoute
$\mathcal{E}$	L'ensemble des effets médiés	Les chemins indirects
ψ_{ij}	Effet médié de i sur j	Ce que i ajoute via j

En langage naturel :

« Prédiction = base + contributions directes + effets médiés »

1.4 Démonstration intuitive

Pourquoi est-ce nécessaire ?
SHAP suppose que les variables sont **indépendantes**. Mais dans la réalité, elles sont **corrélées** :

— Code postal → Revenus

— Revenus → Historique de crédit

Si on utilise SHAP seul, on attribue *tout* l'effet au code postal. On **surévalue** son rôle.
DCME corrige cela en séparant :

— Ce qui agit **directement**

— Ce qui agit **par l'intermédiaire** d'autres variables

1.5 Objections fréquentes

? Objections fréquentes

« **SHAP ne suffit pas déjà ?** » — Non. SHAP est une première couche. DCME est une deuxième couche qui affine l'attribution en distinguant les chemins directs et médiés.
« **Ça ne rend pas le modèle plus complexe à expliquer ?** » — Au contraire : DCME produit des explications *plus lisibles* parce qu'il sépare ce qui est vraiment direct de ce qui est indirect.
« **Comment sait-on qu'un effet est médié ?** » — Par le *graphe causal* : un diagramme qui relie les variables selon des relations causales connues (expertise métier + tests statistiques).

1.6 Trois niveaux d'explication

Pour un enfant de 10 ans

« Imagine que tu es mouillé. Pourquoi ? Parce qu'il pleut. Mais pourquoi il pleut ? Parce qu'il y a des nuages. Et pourquoi il y a des nuages ? Parce qu'il fait chaud.
DCME, c'est pareil : il ne dit pas juste "tu es mouillé parce qu'il pleut", il explique **toute la chaîne** : chaud → nuages → pluie → mouillé. »

Pour un dirigeant

« Votre modèle refuse un client. SHAP vous dit "code postal −15 %". Mais ça ne vous dit pas *pourquoi*. Est-ce un facteur direct, ou un proxy d'inégalités structurelles ?
DCME vous donne cette réponse. Vous savez si votre modèle **discrimine directement** ou s'il **capture des inégalités existantes**. Deux situations juridiquement très différentes. »

Pour un chercheur

« DCME étend SHAP en intégrant une décomposition causale multi-échelle. Là où SHAP produit ϕ_i pour chaque variable i, DCME produit $\phi_i^{(s)}$ pour chaque variable i à chaque échelle s, plus ψ_{ij} pour chaque effet médié.
La contrainte d'additivité devient : $\sum_{s,i} \phi_i^{(s)} + \sum_{(i,j)} \psi_{ij} = \hat{y} - \phi_0$. L'intérêt est double : distinguer les effets directs des médiés, et intégrer la notion d'échelle causale. »

1.7 Points clés

1. DCME = SHAP + causalité + multi-échelle
2. Il distingue **effets directs** et **effets médiés**
3. Il organise l'explication en **plusieurs échelles** (micro, méso, macro)
4. Il **corrige** la surestimation des variables corrélées
5. Il est **défendable** réglementairement

Chapitre 2

ECS — Score de Cohérence des Explications

Idée clé

ECS mesure si une explication d'IA reste stable quand on change très légèrement la situation.

2.1 L'analogie du quotidien

Analogie du quotidien

Imaginez un médecin. Vous lui décrivez vos symptômes :
Lundi : « J'ai mal à la tête, un peu de fièvre. » → Diagnostic : grippe.
Mardi : « J'ai mal à la tête, un peu de fièvre, et j'ai éternué une fois. » → Diagnostic : **cancer rare** ?
Ce médecin n'est pas fiable. Une infime variation ne devrait pas changer radicalement le diagnostic.
ECS mesure exactement cela pour les IA : il vérifie que deux situations très proches produisent des explications très proches.

2.2 Exemple concret

Contexte : un modèle de détection de fraude bancaire.

Cas	Situation	Explication attendue
1	Montant 1 000 €, minuit	Montant +40 %, Heure +35 %
2	Montant 1 001 €, minuit	Quasi identique (attendu)
3	Montant 1 002 €, minuit	Quasi identique (attendu)

Si le modèle produit des explications **radicalement différentes** pour ces trois cas, l'explication est **instable**, le modèle est **fragile**, et ses explications ne sont **pas défendables**.

ECS quantifie cette stabilité.

2.3 La formule expliquée mot par mot

Formule expliquée

$$\mathrm{ECS}(f, x, \epsilon) = 1 - \frac{1}{N} \sum_{k=1}^{N} \frac{\|\phi(f, x) - \phi(f, x_k)\|_1}{\|\phi(f, x)\|_1 + \delta} \tag{2.1}$$

Symbole	Signification	Analogie
f	Le modèle d'IA	Le médecin
x	L'instance de départ	Votre situation lundi
ϵ	Le rayon de perturbation	De combien on varie les symptômes
N	Le nombre de voisins testés	Combien de variantes on teste
x_k	Le k-ème voisin	Une variante de votre situation
$\phi(f, x)$	L'explication pour x	Diagnostic pour lundi
$\|\cdot\|_1$	Norme L1 (somme des valeurs absolues)	La « distance » entre explications

En langage naturel :

« ECS = 1 − (distance moyenne aux voisins, normalisée) »

— Si les explications sont **identiques** → distance = 0 → **ECS = 1** (parfait)

— Si les explications sont **très différentes** → **ECS proche de 0** (mauvais)

— ECS est toujours entre **0 et 1**

2.4 Démonstration intuitive

1. **Choix du point de départ** : un client précis.
2. **Génération des voisins** : 100 clients dont le profil diffère de ±5 %.
3. **Calcul des explications** : pour chacun, on calcule ϕ (SHAP par exemple).
4. **Comparaison** : on mesure la distance entre chaque voisin et le point de départ.
5. **Agrégation** : moyenne des distances, puis normalisation.
6. **Inversion** : plus la distance est petite, plus ECS est grand.

2.5 Interprétation

ECS	Interprétation	Action
≥ 0.80	Stable	Valider, mettre en production
$0.50 - 0.80$	Modéré	Surveiller, améliorer
< 0.50	Instable	Incident à ouvrir, blocage possible

2.6 Objections fréquentes

? Objections fréquentes

« Pourquoi mesurer la stabilité, et pas la justesse ? » — La justesse mesure si l'explication est *correcte*. La stabilité mesure si elle est *cohérente*. ECS mesure la seconde. Pour un régulateur, la stabilité est *aussi importante* que la justesse.
« Comment choisir ϵ ? » — En pratique : **5 % de l'écart-type** par variable.
« ECS remplace SHAP ? » — Non. ECS s'applique à *n'importe quelle* méthode d'explication.

2.7 Trois niveaux d'explication

Pour un enfant de 10 ans

« Tu dessines un bonhomme. Puis je te demande de dessiner presque le même. Si ton deuxième dessin est complètement différent, tu n'es pas cohérent.
ECS, c'est pareil : on demande à l'IA d'expliquer une décision, puis presque la même. Si les explications sont trop différentes, l'IA n'est pas fiable. »

Pour un dirigeant

« Si un régulateur vous demande pourquoi le modèle a refusé un client, et aussi pourquoi il a refusé un client *très similaire*, vos deux réponses doivent être **cohérentes**.
ECS mesure cela. Un ECS élevé signifie que le modèle est défendable. Un ECS faible signifie qu'il est **fragile juridiquement**. »

Pour un chercheur

« ECS est une métrique de robustesse locale des explications. Formellement, pour un voisinage $\mathcal{N}_\epsilon(x)$, on calcule la distance normalisée entre l'explication au point x et celles des points voisins. La normalisation par $\|\phi(f,x)\|_1 + \delta$ garantit que ECS est borné dans $[0,1]$, ce qui le rend **comparable entre méthodes**. C'est le progrès principal par rapport à la sensibilité brute (Yeh et al., 2019). »

2.8 Points clés

1. ECS mesure la **stabilité** d'une explication
2. Il varie entre **0 (instable) et 1 (stable)**
3. Il s'applique à **n'importe quelle méthode**
4. Il est **normalisé** et **comparable**
5. Seuil recommandé pour haut risque : ≥ 0.80

Chapitre 3

RAD — Dette de Responsabilité Algorithmique

Idée clé

RAD mesure combien votre organisation accumule de « retard » dans la gouvernance de ses systèmes d'IA.

3.1 L'analogie du quotidien

Analogie du quotidien

Imaginez une maison que vous n'entretenez jamais.

— **Année 1** : une gouttière fuit. Vous ne réparez pas. → Petit problème.

— **Année 2** : l'eau s'infiltre. Vous ne réparez pas. → Problème plus gros.

— **Année 3** : le mur s'effondre. → Catastrophe.

Le coût de réparation augmente avec le temps. C'est la **dette technique**.
RAD applique ce principe à la gouvernance de l'IA : si votre organisation n'entretient pas ses systèmes, elle accumule une dette qui se transformera en crise.

3.2 Exemple concret

Contexte : une organisation exploite 20 systèmes d'IA. Elle n'en gouverne correctement que 10.

Système	Attendu	Réel	Écart
A (crédit)	8	4	4
B (recrutement)	7	5	2

Sur 6 mois :

— Système A : écart cumulé $= 4 \times 6 = 24$

— Système B : écart cumulé $= 2 \times 6 = 12$

RAD = somme pondérée des écarts sur tous les systèmes et tous les mois.

Un RAD élevé signifie : « votre organisation **accumule du retard**, et chaque mois d'inaction augmente le coût futur de mise en conformité. »

3.3 La formule expliquée mot par mot

Formule expliquée

$$\mathrm{RAD}_i(T) = \sum_{t=1}^{T} \alpha_t \cdot \max\left(0, S^{(i)}_{\texttt{attendu}}(t) - S^{(i)}_{\texttt{effectif}}(t)\right) \cdot \beta_i \tag{3.1}$$

Symbole	Signification	Analogie
$\texttt{RAD}_i(T)$	Dette du système i sur horizon T	Coût de réparation
T	Horizon temporel (mois)	Nombre d'années sans entretien
α_t	Facteur de récence	Plus le retard est récent, plus il compte
$S_{\texttt{attendu}}$	Niveau attendu	Niveau d'entretien recommandé
$S_{\texttt{effectif}}$	Niveau réel	Niveau d'entretien réel
β_i	Coefficient de criticité AI Act	Gravité du système

Facteur de récence :

$$\alpha_t = e^{-\lambda(T-t)}, \quad \lambda \approx 0.1 \tag{3.2}$$

Coefficient de criticité :

Catégorie AI Act	β
Risque minimal	1
Risque limité (art. 50)	2
Haut risque (annexe I)	3
Haut risque (annexe III)	4

RAD normalisé :

$$\mathrm{RAD}_{\mathrm{norm}}(T) = \frac{\mathrm{RAD}_{\mathrm{portfolio}}(T)}{N \cdot \beta_{\max} \cdot S_{\max}} \tag{3.3}$$

avec $\beta_{\max} = 4$ et $S_{\max} = 9$.

3.4 Interprétation

$\mathbf{RAD_{norm}}$	Interprétation	Action
< 0.10	Aligné	Maintenir les efforts
$0.10 - 0.25$	Modéré	Plan d'amélioration
≥ 0.25	Critique	Arbitrage budgétaire urgent

3.5 Objections fréquentes

? Objections fréquentes

« **Pourquoi cumulatif et pas instantané ?** » — Parce que la dette *s'accumule*. Un écart instantané ne dit rien sur la trajectoire.
« **Comment fixer $S_{\texttt{attendu}}$?** » — C'est une décision de gouvernance. On fixe une roadmap

cible (« en M12, tous les systèmes haut risque doivent atteindre S8 »).
« Et si un système est en avance ? » — On ne compte que les écarts *positifs* via $\max(0, \dots)$.
« RAD n'est-il pas trop abstrait ? » — Non. RAD a une *interprétation économique directe* : coût futur de mise en conformité, convertible en euros ou jours-homme.

3.6 Trois niveaux d'explication

Pour un enfant de 10 ans

« Imagine que ta chambre se salit un peu chaque jour. Si tu ne ranges pas, au bout de 100 jours, c'est un désastre.
RAD, c'est pareil : il compte combien de temps tu as laissé traîner les choses dans la gouvernance de tes IA. Plus tu attends, plus ça coûtera cher. »

Pour un dirigeant

« Si vous ne gouvernez pas vos systèmes d'IA, vous accumulez une **dette** qui se transformera en crise (amendes, perte de confiance, contentieux).
RAD mesure cette dette. Un RAD faible signifie que vous êtes aligné. Un RAD élevé signifie que le coût futur de mise en conformité augmente. C'est un indicateur pilotable en comité de direction. »

Pour un chercheur

« RAD transpose la notion de dette technique (Cunningham, 1992) à la responsabilité algorithmique. Formellement, c'est une somme pondérée temporellement des écarts entre maturité attendue et effective.
Le facteur $\alpha_t = e^{-\lambda(T-t)}$ privilégie les écarts récents. Le coefficient β_i intègre la criticité AI Act. La normalisation permet la comparaison inter-organisations. À notre connaissance, c'est la première formalisation de la dette de responsabilité algorithmique. »

3.7 Points clés

1. RAD mesure la **dette de gouvernance IA**
2. Il est **cumulatif** (pas instantané)
3. Il intègre un **facteur de récence**
4. Il intègre un **coefficient de criticité** AI Act
5. Il a une **interprétation économique**

Synthèse transversale

4.1 Comment articuler les trois concepts ?

Concept	Rôle	Question	Pilier
DCME	Améliore la qualité	*Pourquoi cette décision ?*	F
ECS	Mesure la stabilité	*Cette explication est-elle fiable ?*	M
RAD	Mesure la dette	*Où en est-on, collectivement ?*	G



4.2 Comment défendre ces concepts

Question type 1 : « En quoi DCME est-il différent de SHAP ? »

SHAP fournit une décomposition additive à une seule échelle. DCME étend SHAP en intégrant (1) la causalité via les effets médiés, et (2) la multi-échelle via les niveaux micro, méso, macro. La contrainte d'additivité est préservée, mais la richesse explicative est supérieure.

Question type 2 : « ECS est-il vraiment original ? »

Des travaux existent sur la robustesse des explications (Alvarez-Melis & Jaakkola, 2018 ; Yeh et al., 2019). Mais ECS apporte une **normalisation explicite** qui le rend borné dans $[0, 1]$ et **comparable entre méthodes**. C'est ce qui le distingue des métriques précédentes.

Question type 3 : « RAD n'est-il pas trop abstrait ? »

RAD a une **interprétation économique directe** : le coût futur de mise en conformité. Il peut être converti en euros ou en jours-homme. De plus, il est **normalisable**, permettant la comparaison et le suivi de trajectoire.

Deuxième partie

Exercices et corrections

Exercices — DCME

5.1 Exercice 1 — Identifier les niveaux d'analyse (facile)

Exercice

Un modèle d'IA prédit la réussite d'un étudiant à un examen. Voici les données utilisées :

- Note au baccalauréat
- Revenu des parents
- Quartier de résidence
- Nombre d'heures de révision
- Présence en cours
- Établissement fréquenté (public/privé)

Question : Répartissez ces variables en trois échelles (micro, méso, macro) selon le niveau d'analyse causal qui vous paraît le plus pertinent.

Correction

Proposition de répartition :
Micro (variable individuelle) :

- Note au baccalauréat
- Nombre d'heures de révision
- Présence en cours

Méso (contexte proche) :

- Revenu des parents
- Établissement fréquenté

Macro (contexte systémique) :

- Quartier de résidence

Justification : les variables micro sont des caractéristiques de l'individu lui-même. Les variables méso décrivent son environnement familial et institutionnel immédiat. Les variables macro reflètent des réalités structurelles plus larges.
Remarque : il n'existe pas de réponse unique. L'important est que la répartition soit *cohérente* et *justifiée*. Le graphe causal doit être discuté avec des experts métier.

5.2 Exercice 2 — Distinguer effet direct et effet médié (moyen)

Exercice

Un modèle de scoring crédit utilise les variables suivantes :

— Origine géographique

— Revenu mensuel

— Historique de crédit

On observe les corrélations suivantes :

— Origine géographique → Revenu : corrélation forte ($-0{,}6$)

— Revenu → Décision : corrélation forte ($+0{,}7$)

— Origine géographique → Décision : corrélation modérée ($-0{,}3$)

Questions :

1. Identifiez l'effet direct de l'origine géographique sur la décision.
2. Identifiez l'effet médié par le revenu.
3. Expliquez pourquoi SHAP surestimerait probablement l'effet direct.

Correction

1. Effet direct : la corrélation de $-0{,}3$ entre l'origine géographique et la décision représente l'effet **direct** (une fois qu'on contrôle les autres variables).
2. Effet médié : l'effet indirect passe par le revenu. On peut l'estimer approximativement par :

$$\psi_{\text{origine, revenu}} \approx (-0{,}6) \times (+0{,}7) = -0{,}42 \tag{5.1}$$

3. Pourquoi SHAP surestime : SHAP traite chaque variable indépendamment et attribue à l'origine géographique *à la fois* l'effet direct ($-0{,}3$) *et* l'effet médié ($-0{,}42$), soit au total environ $-0{,}72$. Il ne distingue pas les chemins, ce qui fait apparaître l'origine géographique comme plus déterminante qu'elle ne l'est en réalité.
Conséquence pratique : cette surestimation peut faire croire à une discrimination *directe*, alors que le modèle ne fait que capturer une *corrélation structurelle* entre origine et revenu. DCME permet de clarifier cette distinction, essentielle juridiquement.

5.3 Exercice 3 — Appliquer la formule DCME (difficile)

Exercice

On considère un modèle avec deux échelles ($\mathcal{S} = \{\text{micro}, \text{macro}\}$) et trois variables ($X_1, X_2, X_3$). Données :

— Prédiction $\hat{y} = 0{,}80$

— Baseline $\phi_0 = 0{,}50$

— Contributions directes :

  — $\phi_1^{(\text{micro})} = 0{,}10$

  — $\phi_2^{(\text{micro})} = 0{,}05$

  — $\phi_3^{(\text{macro})} = 0{,}08$

— Effet médié : $\psi_{12} = 0{,}07$

Questions :

1. La contrainte d'additivité est-elle satisfaite ?
2. Si non, quelle valeur manque-t-il ?
3. Que peut-on conclure sur le modèle ?

Correction

1. Vérification de la contrainte d'additivité :

$$\phi_0 + \sum_s \sum_i \phi_i^{(s)} + \sum_{(i,j)} \psi_{ij} = 0{,}50 + (0{,}10 + 0{,}05 + 0{,}08) + 0{,}07 \tag{5.2}$$

$$= 0{,}50 + 0{,}23 + 0{,}07 \tag{5.3}$$

$$= 0{,}80 \tag{5.4}$$

Et $\hat{y} = 0{,}80$. Donc la contrainte **est satisfaite**.

2. Aucune valeur manquante.

3. Conclusion : la décomposition est cohérente. On peut interpréter :

— La prédiction est supérieure de 0,30 à la baseline.

— Sur ce delta : 0,23 viennent d'effets directs (+77 %) et 0,07 d'effets médiés (+23 %).

— L'effet médié $\psi_{12} = 0{,}07$ indique que X_1 influence X_2, qui influence à son tour la décision.

Interprétation managériale : une partie significative de la décision (23 %) provient de chemins *indirects*. Toute action corrective doit donc porter non seulement sur les variables elles-mêmes, mais aussi sur leurs corrélations.

Exercices — ECS

6.1 Exercice 4 — Calculer un ECS simple (facile)

Exercice

On considère un modèle f et une instance x. On calcule l'explication $\phi(f, x)$ et trois explications de voisins :

$$\phi(f, x) = [0{,}40,\ -0{,}20,\ 0{,}30] \tag{6.1}$$
$$\phi(f, x_1) = [0{,}42,\ -0{,}18,\ 0{,}28] \tag{6.2}$$
$$\phi(f, x_2) = [0{,}38,\ -0{,}22,\ 0{,}32] \tag{6.3}$$
$$\phi(f, x_3) = [0{,}39,\ -0{,}21,\ 0{,}31] \tag{6.4}$$

Avec $\delta = 0{,}01$ et en utilisant la norme L1.

Questions :

1. Calculez $\|\phi(f, x)\|_1$.
2. Calculez les trois distances $\|\phi(f, x) - \phi(f, x_k)\|_1$.
3. En déduire $\text{ECS}(f, x, \epsilon)$.
4. Interprétez le résultat.

Correction

1. Norme L1 de $\phi(f, x)$:

$$\|\phi(f, x)\|_1 = |0{,}40| + |-0{,}20| + |0{,}30| = 0{,}90 \tag{6.5}$$

2. Distances :

$$\|\phi(f, x) - \phi(f, x_1)\|_1 = |0{,}40 - 0{,}42| + |-0{,}20 + 0{,}18| + |0{,}30 - 0{,}28| \tag{6.6}$$
$$= 0{,}02 + 0{,}02 + 0{,}02 = 0{,}06 \tag{6.7}$$
$$\|\phi(f, x) - \phi(f, x_2)\|_1 = 0{,}02 + 0{,}02 + 0{,}02 = 0{,}06 \tag{6.8}$$
$$\|\phi(f, x) - \phi(f, x_3)\|_1 = 0{,}01 + 0{,}01 + 0{,}01 = 0{,}03 \tag{6.9}$$

3. Calcul de ECS :

$$\text{ECS}(f, x, \epsilon) = 1 - \frac{1}{3} \cdot \frac{0{,}06 + 0{,}06 + 0{,}03}{0{,}90 + 0{,}01} \tag{6.10}$$

$$= 1 - \frac{1}{3} \cdot \frac{0{,}15}{0{,}91} \tag{6.11}$$

$$= 1 - \frac{0{,}15}{2{,}73} \tag{6.12}$$

$$\approx 1 - 0{,}055 \tag{6.13}$$

$$\approx 0{,}945 \tag{6.14}$$

4. Interprétation : ECS $\approx 0{,}945 \geq 0{,}80$. L'explication est **très stable**. On peut la valider et l'utiliser en production.

6.2 Exercice 5 — Comparer deux méthodes (moyen)

Exercice

On souhaite comparer SHAP et LIME sur un même modèle, en utilisant ECS.
On effectue 100 mesures d'ECS pour chaque méthode :

— SHAP : moyenne ECS = 0,85, écart-type = 0,03

— LIME : moyenne ECS = 0,62, écart-type = 0,08

Questions :

1. Quelle méthode est la plus stable ?
2. Quelle méthode est la plus prévisible ?
3. Quelle recommandation feriez-vous à l'équipe technique ?

Correction

1. Stabilité : SHAP a un ECS moyen plus élevé ($0{,}85 > 0{,}62$). SHAP est donc **plus stable**.
2. Prévisibilité : SHAP a un écart-type plus faible ($0{,}03 < 0{,}08$). Les résultats de SHAP sont plus **homogènes**. LIME a des résultats beaucoup plus variables selon les instances.
3. Recommandation :

— Pour les modèles à **haut risque**, utiliser SHAP (stable, prévisible).

— Pour les modèles à **risque limité**, LIME peut suffire.

— Documenter les écarts-types dans la fiche modèle : ils indiquent la *fiabilité* de la méthode, pas seulement sa performance moyenne.

Point clé : un ECS moyen de 0,62 pour LIME reste au-dessus du seuil 0,50. LIME n'est pas « mauvais » : il est simplement moins prévisible.

6.3 Exercice 6 — Détecter une instabilité (difficile)

Exercice

Une équipe vous présente les résultats suivants pour un modèle de scoring crédit :

Instance	SHAP de la variable « code postal »	SHAP de la variable « revenu »
Client A (revenu 2 500 €)	−0,15	−0,20
Client B (revenu 2 510 €)	−0,35	−0,05
Client C (revenu 2 490 €)	+0,10	−0,30

Les trois clients ont des profils quasi identiques (écart de 1 %).
Questions :

1. Ces résultats sont-ils cohérents ?
2. Calculez un ECS approximatif entre A et B, puis entre A et C.
3. Que concluez-vous ?

Correction

1. Cohérence : les trois clients ont des profils quasi identiques, mais les explications varient fortement (code postal : de −0,35 à +0,10, soit une amplitude de 0,45). Les résultats sont **incohérents**.
2. Calcul approximatif :
Distance L1 entre A et B :

$$\|\phi_A - \phi_B\|_1 = |0{,}15 - 0{,}35| + |0{,}20 - 0{,}05| = 0{,}20 + 0{,}15 = 0{,}35 \tag{6.15}$$

Distance L1 entre A et C :

$$\|\phi_A - \phi_C\|_1 = |0{,}15 + 0{,}10| + |0{,}20 - 0{,}30| = 0{,}25 + 0{,}10 = 0{,}35 \tag{6.16}$$

Norme L1 de ϕ_A :

$$\|\phi_A\|_1 = 0{,}15 + 0{,}20 = 0{,}35 \tag{6.17}$$

ECS approximatif (avec $\delta = 0{,}01$) :

$$\mathrm{ECS}(A) \approx 1 - \frac{0{,}35}{0{,}36} \approx 1 - 0{,}97 \approx 0{,}03 \tag{6.18}$$

3. Conclusion : ECS $\approx 0{,}03 \ll 0{,}50$. L'explication est **très instable**. C'est un **incident à ouvrir**.
Actions recommandées :

— Analyser les causes (drift ? biais d'échantillonnage ? sur-apprentissage ?)
— Vérifier la cohérence des données d'entrée
— Envisager un réentraînement ou un recalibrage
— Bloquer la mise en production tant que ECS $< 0{,}50$

Exercices — RAD

7.1 Exercice 7 — Calculer un RAD simple (facile)

Exercice

Une organisation exploite un seul système d'IA : un scoring crédit classé **haut risque annexe III** ($\beta = 4$).
Sur 3 mois, on observe :

Mois (t)	S_{attendu}	S_{effectif}
1	6	4
2	7	5
3	7	6

Avec $\lambda = 0{,}1$, calculez $\text{RAD}(T = 3)$.

Correction

Étape 1 : calcul des facteurs de récence $\alpha_t = e^{-0{,}1(3-t)}$.

— $t = 1$: $\alpha_1 = e^{-0{,}1\times 2} = e^{-0{,}2} \approx 0{,}819$

— $t = 2$: $\alpha_2 = e^{-0{,}1\times 1} = e^{-0{,}1} \approx 0{,}905$

— $t = 3$: $\alpha_3 = e^{0} = 1{,}000$

Étape 2 : calcul des écarts pondérés.

— $t = 1$: $(6 - 4) = 2$; contribution $= 0{,}819 \times 2 \times 4 = 6{,}552$

— $t = 2$: $(7 - 5) = 2$; contribution $= 0{,}905 \times 2 \times 4 = 7{,}240$

— $t = 3$: $(7 - 6) = 1$; contribution $= 1{,}000 \times 1 \times 4 = 4{,}000$

Étape 3 : somme.

$$\text{RAD}(T = 3) = 6{,}552 + 7{,}240 + 4{,}000 = 17{,}792 \tag{7.1}$$

Interprétation : la dette brute est de 17,792 unités. C'est un indicateur brut, à interpréter en regard du RAD normalisé (voir exercice suivant).

7.2 Exercice 8 — RAD normalisé (moyen)

Exercice

Reprenons l'exercice précédent. On considère un portefeuille de $N = 3$ systèmes, tous classés haut risque annexe III ($\beta_{\max} = 4$), avec $S_{\max} = 9$.
Supposons que le RAD portefeuille total soit de 45 unités.
Questions :

1. Calculez le RAD normalisé.
2. Interprétez le résultat.
3. Que recommandez-vous à la direction ?

Correction

1. Calcul :

$$\mathrm{RAD}_{\mathrm{norm}} = \frac{45}{3 \times 4 \times 9} = \frac{45}{108} \approx 0{,}417 \tag{7.2}$$

2. Interprétation : $\mathrm{RAD}_{\mathrm{norm}} = 0{,}417 \geq 0{,}25$. Le RAD est **critique**.
3. Recommandation à la direction :

— La dette de responsabilité algorithmique est élevée.
— Un arbitrage budgétaire urgent est nécessaire.
— Prioriser les systèmes avec le RAD individuel le plus élevé (voir exercice suivant).
— Mettre en place un plan d'amélioration avec jalons trimestriels.
— Communiquer le RAD en COMEX comme un indicateur de risque stratégique.

7.3 Exercice 9 — Priorisation par RAD (difficile)

Exercice

Une organisation exploite 5 systèmes d'IA. Voici leurs caractéristiques sur un horizon de 6 mois :

Système	Catégorie AI Act	β	$\mathrm{RAD}_i(T = 6)$
A	Haut risque annexe III	4	28
B	Haut risque annexe I	3	15
C	Risque limité (art. 50)	2	18
D	Haut risque annexe III	4	8
E	Risque minimal	1	5

Questions :

1. Classez les systèmes par RAD décroissant.
2. Calculez le RAD portefeuille et le RAD normalisé.
3. Proposez un ordre de priorisation des actions correctives.

Correction

1. Classement par RAD décroissant :

1. A : RAD $= 28$ ($\beta = 4$)
2. C : RAD $= 18$ ($\beta = 2$)
3. B : RAD $= 15$ ($\beta = 3$)
4. D : RAD $= 8$ ($\beta = 4$)
5. E : RAD $= 5$ ($\beta = 1$)

2. RAD portefeuille et normalisé :

$$\mathrm{RAD}_{\mathrm{portfolio}} = 28 + 18 + 15 + 8 + 5 = 74 \tag{7.3}$$

$$\mathrm{RAD}_{\mathrm{norm}} = \frac{74}{5 \times 4 \times 9} = \frac{74}{180} \approx 0{,}411 \tag{7.4}$$

3. Ordre de priorisation :
Approche brute (par RAD) : A > C > B > D > E.
Approche critique : il faut pondérer par la criticité β.

— A : RAD$/\beta = 28/4 = 7$ — système à haut risque, priorité maximale
— C : RAD$/\beta = 18/2 = 9$ — le *ratio* est le plus élevé
— B : RAD$/\beta = 15/3 = 5$
— D : RAD$/\beta = 8/4 = 2$
— E : RAD$/\beta = 5/1 = 5$

Recommandation :

1. **Priorité 1** : A (haut risque + RAD absolu le plus élevé)
2. **Priorité 2** : C (ratio RAD$/\beta$ le plus élevé, coût par unité de criticité)
3. **Priorité 3** : B (haut risque modéré)
4. **Priorité 4** : E (risque minimal, faible priorité malgré le ratio)
5. **Priorité 5** : D (déjà bien gouverné malgré le haut risque)

Point clé : le RAD brut ne suffit pas. Il faut le croiser avec la criticité β et la classification AI Act pour prioriser efficacement.

Exercices transversaux

8.1 Exercice 10 — Choisir la bonne méthode (moyen)

Exercice

Une équipe vous demande conseil pour choisir la méthode d'explication adaptée à chaque cas :

Cas	Contexte	Classification AI Act
1	XGBoost de scoring crédit, avec corrélations fortes entre variables	Haut risque (annexe III)
2	Réseau de neurones de recommandation produit, faible enjeu	Risque minimal
3	Système multi-agents de détection de fraude, avec graphe causal connu	Haut risque (annexe III)

Questions : Recommandez pour chaque cas :

1. La méthode d'explication (SHAP, LIME ou DCME)
2. Le niveau de profondeur XAI requis
3. La fréquence de réévaluation

Correction

Cas 1 — Scoring crédit (haut risque, corrélations fortes) :

— Méthode recommandée : **SHAP + DCME** (complémentaires)

— Pourquoi : SHAP fournit la décomposition additive ; DCME distingue les effets directs et médiés dans un contexte où les corrélations sont fortes.

— Profondeur XAI : **complète** (explication individuelle réglementairement défendable)

— Fréquence : **trimestrielle** + sur incident

Cas 2 — Recommandation produit (risque minimal) :

— Méthode recommandée : **LIME** (léger, suffisant)

— Pourquoi : faible enjeu, pas besoin de causalité ni de multi-échelle.

— Profondeur XAI : **documentation des variables** et comportement attendu

— Fréquence : **annuelle**

Cas 3 — Multi-agents fraude (haut risque, graphe causal connu) :

— Méthode recommandée : **DCME** (prioritaire)

— Pourquoi : le graphe causal est connu, ce qui est une condition d'application idéale pour DCME. La nature multi-agents justifie la multi-échelle.

— Profondeur XAI : **complète**, avec ECS élevé (≥ 0.80)

— Fréquence : **trimestrielle** + sur incident

Règle générale : plus le risque AI Act est élevé, plus la méthode d'explication doit être riche et la fréquence de réévaluation élevée. Le principe de proportionnalité s'applique.

8.2 Exercice 11 — Étude de cas complète (difficile)

Exercice

Une banque utilise un modèle de scoring crédit classé **haut risque annexe III** ($\beta = 4$). Voici les données :

Modèle :

— Type : XGBoost

— Variables : 15, dont 3 fortement corrélées

— ECS actuel : 0,68

Système (AEXIA-S) :

— Niveau attendu (M12) : S8

— Niveau effectif actuel : S5

Historique sur 6 mois :

— S_{attendu} reste à 8 à partir du mois 3

— S_{effectif} : 4, 4, 5, 5, 5, 5

Questions :

1. Calculez le RAD de ce système sur T=6.
2. ECS est-il acceptable ? Sinon, quelle action prioritaire ?
3. Quelles méthodes d'explication recommandez-vous ?
4. Proposez un plan d'action structuré en 3 étapes.

Correction

1. Calcul du RAD :

Écarts et facteurs de récence ($\lambda = 0{,}1$) :

t	S_{attendu}	S_{effectif}	Écart	α_t
1	6	4	2	$e^{-0,5} \approx 0{,}607$
2	7	4	3	$e^{-0,4} \approx 0{,}670$
3	8	5	3	$e^{-0,3} \approx 0{,}741$
4	8	5	3	$e^{-0,2} \approx 0{,}819$
5	8	5	3	$e^{-0,1} \approx 0{,}905$
6	8	5	3	1,000

Contributions ($\alpha_t \times$ écart $\times \beta$) :

— $t = 1$: $0{,}607 \times 2 \times 4 = 4{,}856$

— $t = 2$: $0{,}670 \times 3 \times 4 = 8{,}040$

— $t = 3$: $0{,}741 \times 3 \times 4 = 8{,}892$

— $t = 4$: $0{,}819 \times 3 \times 4 = 9{,}828$

— $t = 5$: $0{,}905 \times 3 \times 4 = 10{,}860$

— $t = 6$: $1{,}000 \times 3 \times 4 = 12{,}000$

$$\text{RAD}(T = 6) = 4{,}856 + 8{,}040 + 8{,}892 + 9{,}828 + 10{,}860 + 12{,}000 = 54{,}476 \tag{8.1}$$

2. ECS acceptable ?
ECS actuel = 0,68. C'est dans la zone **modérée** (0,50–0,80), en dessous du seuil cible pour haut risque ($\geq 0{,}80$).
Action prioritaire : ouvrir un chantier d'amélioration de la stabilité. Trois pistes :

— Vérifier la stabilité des données d'entrée (drift ?)

— Augmenter la taille des échantillons pour SHAP (moins de bruit)

— Passer à TreeSHAP exact au lieu d'approximation

3. Méthodes d'explication recommandées :

— **SHAP (TreeSHAP)** : pour la décomposition standard

— **DCME** : pour distinguer les effets directs des effets médiés dans un contexte de corrélations fortes

— **ECS** : en mesure systématique pour surveiller la stabilité

4. Plan d'action structuré en 3 étapes :
Étape 1 (0–3 mois) — Stabilisation :

— Diagnostic de l'instabilité

— Migration vers TreeSHAP exact

— Objectif : ECS $\geq 0{,}80$

Étape 2 (3–9 mois) — Passage S5 $\rightarrow$ S6 :

— Formaliser la méthode XAI retenue

— Définir les seuils de qualité

— Franchir la porte critique S5 $\rightarrow$ S6 en DGC

Étape 3 (9–12 mois) — Préparation S7 $\rightarrow$ S8 :

— Dossier de conformité complet

— Jeu de référence figé

— Procédure de surveillance humaine

— Validation finale DGC + DPO

Indicateurs de succès :

— ECS $\geq 0{,}80$ en continu

— Niveau AEXIA-S $\geq$ S7 en M12

— RAD stabilisé (pas de croissance)

8.3 Exercice 12 — Défense en soutenance (difficile)

Exercice

Vous êtes en soutenance devant un jury interdisciplinaire (mathématicien, juriste, praticien). Le jury vous pose les trois questions suivantes :

1. *(Mathématicien)* « En quoi DCME est-il mathématiquement supérieur à SHAP ? »
2. *(Juriste)* « Comment ECS peut-il être opposable à un régulateur ? »
3. *(Praticien)* « Quelle est la valeur économique de RAD pour une organisation ? »

Questions : Rédigez une réponse structurée pour chaque question (5–8 lignes par réponse).

Correction

1. Réponse au mathématicien :
SHAP fournit une décomposition additive à une seule échelle, sous hypothèse d'indépendance (ou approximée par marginalisation). DCME étend cette décomposition à deux dimensions : (a) la causalité, via les effets médiés ψ_{ij} qui capturent les chemins indirects selon un graphe causal ; (b) la multi-échelle, via les indices (s) qui distinguent micro, méso et macro. Formellement, SHAP est un cas particulier de DCME lorsque $\mathcal{S} = \{1\}$ et $\mathcal{E} = \emptyset$. La contrainte d'additivité est préservée, la richesse explicative est supérieure.
2. Réponse au juriste :
ECS est une métrique bornée dans $[0, 1]$, calculée selon un protocole reproductible (voisinage $\mathcal{N}_\epsilon(x)$, norme L1, normalisation par $\|\phi(f, x)\|_1 + \delta$). Il permet de *démontrer objectivement* que les explications d'un modèle sont stables — donc défendables — pour des situations quasi identiques. En cas de contrôle, l'organisation peut présenter un ECS documenté et justifier que ses explications sont reproductibles, ce qui est au cœur des exigences de l'AI Act (art. 13, 15) et du RGPD art. 22.
3. Réponse au praticien :
RAD a une interprétation économique directe : c'est le coût futur de mise en conformité, exprimé en unités de maturité accumulées. Il peut être converti en euros (coût des audits, des formations, des corrections) ou en jours-homme. Sa normalisation permet de le comparer entre organisations et de suivre sa trajectoire dans le temps. Pour un COMEX, RAD est un indicateur de risque stratégique comparable à la dette technique ou au risque cyber. Un RAD élevé signale une exposition juridique et opérationnelle croissante.

Troisième partie

Annexes

Chapitre 9

Glossaire

Terme	Définition
DCME	Dynamic Causal Multi-scale Explanation — méthode d'explication causale multi-échelle
ECS	Explanation Consistency Score — score de stabilité des explications
RAD	Responsibility Algorithmic Debt — dette de responsabilité algorithmique
SHAP	Méthode de décomposition additive basée sur les valeurs de Shapley
LIME	Approxime localement un modèle complexe par un modèle linéaire
Effet direct	Contribution d'une variable à la prédiction sans intermédiaire
Effet médié	Contribution d'une variable à travers une autre variable
Graphe causal	Diagramme orienté acyclique reliant les variables par des relations causales
Baseline	Valeur moyenne de prédiction (référence des contributions)
Additivité	Propriété $\sum \phi_i = \hat{y} - \phi_0$
AEXIA-O	Axe organisationnel — 6 piliers, niveaux N0 à N5
AEXIA-S	Axe système — 9 niveaux S0 à S9
Maillon faible	Règle : le niveau publié est celui du pilier le plus faible
Rétrogradation	Mécanisme de perte de maturité après dérive ou incident
AI Act	Règlement (UE) 2024/1689 sur l'intelligence artificielle
RGPD art. 22	Droit à l'explication pour décisions automatisées

Chapitre 10

Références

1. SIDIBE, M. (2026). *AEXIA^{TM} Framework — Version 3.0*. IA BIAIS INITIATIVE. DOI : 10.5281/zenodo.23126471.
2. Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS*.
3. Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You ?". *KDD*.
4. Alvarez-Melis, D., & Jaakkola, T. S. (2018). On the Robustness of Interpretability Methods. *ICML Workshop*.
5. Yeh, C.-K., et al. (2019). On the (In)fidelity and Sensitivity of Explanations. *NeurIPS*.
6. Pearl, J. (2009). *Causality : Models, Reasoning, and Inference*. Cambridge University Press.
7. Cunningham, W. (1992). The WyCash Portfolio Management System. *OOPSLA*.
8. Lavin, A., et al. (2022). Technology readiness levels for machine learning systems. *Nature Communications*, 13(1), 6039.
9. Règlement (UE) 2024/1689 (AI Act).
10. Règlement (UE) 2026/1744 (Digital Omnibus).

À propos de l'auteur

Mohamadou SIDIBE

Chief Data Officer · Expert en Gouvernance des Données & IA
Polytechnique ExED 2026
Fondateur, IA BIAIS INITIATIVE
contact@ia-biais-initiative.org

Accountable · *Ethical* · *eXplainable* · *Interpretable* · *Auditable AI*

Ce livret est publié sous licence CC BY 4.0.
Vous êtes libre de le partager et de l'adapter,
à condition de créditer l'auteur original et d'indiquer les modifications.

DOI : 10.5281/zenodo.23126471

Version : 1.0 · Octobre 2026