# AEXIA™ FRAMEWORK

Version 3.0 · Octobre 2026

*Accountable · Ethical · eXplainable · Interpretable · Auditable AI*

## Cadre Intégré de Gouvernance pour l'IA Explicable

Édition Consolidée et Définitive — Fusion V1.0 + V2.0 + V3.0

**Mohamadou SIDIBE**

Chief Data Officer · Expert en Gouvernance des Données & IA
Polytechnique ExED 2026

**Fondateur, IA BIAIS INITIATIVE**

contact@ia-biais-initiative.org

Licence : CC BY 4.0
Classification arXiv : cs.AI · cs.LG · cs.CY
DOI : 10.5281/zenodo.23126471

Fondé sur : DAMA-DMBOK · COBIT · CMMI · NIST AI RMF · EU AI Act · TOGAF · ITIL · et 11 autres frameworks

## Résumé exécutif

AEXIA™ est un cadre intégré de gouvernance de l'IA explicable qui articule, dans une même structure opérationnelle et mesurable, la dimension méthodologique de l'explicabilité, la maturité organisationnelle et la maturité individuelle des systèmes déployés. Il ne se substitue pas aux référentiels existants : il les orchestre autour d'une question qu'aucun ne traite frontalement — celle de la **responsabilité algorithmique des équilibres produits par des systèmes apprenants**.

L'innovation structurante de la version 3.0 est l'**architecture à double axe** :

— **AEXIA™-O** évalue la maturité de l'organisation (6 piliers, 6 niveaux N0 à N5)

— **AEXIA™-S** évalue la maturité de chaque système d'IA déployé (9 niveaux S0 à S9, alignés sur les *Machine Learning Technology Readiness Levels* de Lavin et al., *Nature Communications*, 2022)

Leur croisement produit la **grille de décision d'autorisation de déploiement** — l'instrument le plus directement actionnable du framework.

AEXIA™ intègre également **trois contributions originales** de l'auteur — **DCME, ECS et RAD** — qui constituent le noyau propriétaire du framework et le différencient de toute synthèse de référentiels existants.

**Signification de l'acronyme**

| | | |
|---|---|---|
| **A** | **Accountable** | Redevabilité · traçabilité · audit |
| **E** | **Ethical** | Éthique · dignité humaine · non-discrimination |
| **X** | **eXplainable** | Explicabilité · SHAP · LIME · DCME |
| **I** | **Interpretable** | Interprétabilité · lisibilité · accessibilité |
| **A** | **Auditable** | Auditabilité · conformité · documentation |

| Dimension | Description |
|---|---|
| **Nom complet** | Accountable · Ethical · eXplainable · Interpretable · Auditable AI |
| **6 Piliers (AEXIA™-O)** | Fondements · Architecture · Gouvernance · Conformité · Opérations · Mesure & Amélioration |
| **6 Niveaux maturité org.** | Inexistant (N0) → Initial (N1) → Défini (N2) → Géré (N3) → Avancé (N4) → Excellence (N5) |
| **9 Niveaux maturité sys.** | Premiers principes (S0) → En service surveillé (S9) — alignés MLTRL Lavin et al. 2022 |
| **18 Frameworks sources** | DAMA-DMBOK · COBIT · CMMI · TOGAF · ITIL · NIST AI RMF · EU AI Act · OECD · UNESCO et 9 autres |
| **Cycle de vie AEXIA™** | MAP → DEFINE → BUILD → GOVERN → OPERATE → IMPROVE |
| **Contributions originales** | **DCME · ECS · RAD** — apports propriétaires de Mohamadou SIDIBE |
| **Mécanismes robustesse** | Maillon faible · Portes probantes · Rétrogradation · Proportionnalité |
| **Conformité réglementaire** | EU AI Act (2027) · RGPD art. 22 · OECD AI Principles · UNESCO AI Ethics |
| **Instrument d'évaluation** | Fiche système AEXIA™ Card · Grille d'auto-évaluation · Score AEXIA™ triptyque |
| **DOI** | `10.5281/zenodo.23126471` |

# Sommaire

**Résumé exécutif** **1**

**1 Positionnement et contribution défendable** **5**
1.1 Le vide comblé par AEXIA™ . . . 5
1.2 Formulation de la contribution . . . 5
1.3 Attributions et paternité . . . 6

**2 Architecture à double axe** **6**
2.1 Vue d'ensemble : la correction structurante . . . 6
2.2 Axe O : maturité organisationnelle (AEXIA™-O) . . . 6
2.2.1 Échelle de maturité organisationnelle . . . 7
2.3 Axe S : maturité par système (AEXIA™-S) . . . 7
2.4 Matrice de croisement AEXIA™-O × AEXIA™-S . . . 8

**3 Les 4 mécanismes de robustesse** **8**
3.1 Mécanisme 1 : Règle du maillon faible . . . 9
3.2 Mécanisme 2 : Portes probantes . . . 9
3.3 Mécanisme 3 : Rétrogradation (spécifique à l'IA) . . . 9
3.4 Mécanisme 4 : Proportionnalité au risque . . . 9

**4 Les 6 piliers AEXIA™ en détail** **10**
4.1 Pilier F : Fondements . . . 10
4.2 Pilier A : Architecture . . . 10
4.3 Pilier G : Gouvernance . . . 11
4.4 Pilier C : Conformité . . . 11
4.5 Pilier O : Opérations . . . 11
4.6 Pilier M : Mesure & Amélioration . . . 12

**5 Le noyau original : DCME, ECS et RAD** **12**
5.1 DCME : Dynamic Causal Multi-scale Explanation . . . 12
5.1.1 Définition formelle . . . 12
5.1.2 Formulation mathématique . . . 12
5.1.3 Conditions d'application . . . 13
5.1.4 Limites connues . . . 13
5.1.5 Positionnement vs existant . . . 13
5.1.6 Protocole de mesure . . . 13
5.1.7 Cas d'application démontré . . . 14
5.2 ECS : Explanation Consistency Score . . . 14
5.2.1 Définition formelle . . . 14
5.2.2 Formulation mathématique . . . 14
5.2.3 Conditions d'application . . . 14
5.2.4 Positionnement vs existant . . . 14
5.3 RAD : Responsibility Algorithmic Debt . . . 14
5.3.1 Définition formelle . . . 14
5.3.2 Formulation mathématique . . . 14
5.3.3 Interprétation . . . 15
5.3.4 Positionnement vs existant . . . 15
5.4 Articulation des trois concepts avec les 6 piliers . . . 15

**6 La fiche système AEXIA™ Card** **16**

**7 Cycle de vie AEXIA™** **17**

**8 Modèle de maturité et système de notation** **17**
8.1 Modèle de maturité organisationnelle — 6 piliers × 5 niveaux . . . . . 17
8.2 Système de notation révisé — Le triptyque AEXIA™ . . . . . 17

**9 Conformité réglementaire** **18**

**10 Mapping avec les 18 frameworks sources** **19**

**11 Feuille de route d'implémentation** **19**

**Références** **20**

# 1 Positionnement et contribution défendable

## 1.1 Le vide comblé par AEXIA™

Quatre référentiels structurent aujourd'hui la gouvernance de l'IA, mais aucun ne traite frontalement la question de la **responsabilité algorithmique des équilibres produits par des systèmes apprenants** :

| Référentiel | Ce qu'il fournit | Ce qu'il ne fournit pas |
|---|---|---|
| **NIST AI RMF 1.0** | Cycle 4M (MAP, MEASURE, MANAGE, MONITOR) · 7 caractéristiques de l'IA de confiance | Méthodes XAI (SHAP, LIME) · gouvernance des explications |
| **ISO/IEC 42001** | Système de management de l'IA | Évaluation de la maturité d'un système donné |
| **MLTRL (Lavin et al., 2022)** | Échelle de maturité par système ML (9 niveaux) | Gouvernance organisationnelle · conformité réglementaire |
| **EU AI Act (2024/1689)** | Obligations légales pour les systèmes à haut risque | Instrument de mesure · méthode d'évaluation |

**AEXIA™ se situe à l'intersection de ces quatre espaces.** Il ne se substitue à aucun d'eux : il les orchestre autour d'une question qu'aucun ne traite frontalement — celle de la **responsabilité algorithmique des équilibres produits**.

## 1.2 Formulation de la contribution

**Formulation officielle**

AEXIA™ est un cadre intégré de gouvernance de l'IA explicable qui articule, dans une même structure opérationnelle et mesurable, la dimension méthodologique de l'explicabilité, la maturité organisationnelle et la maturité individuelle des systèmes déployés. Il ne se substitue pas aux référentiels existants : il les orchestre autour d'une question qu'aucun ne traite frontalement — celle de la responsabilité algorithmique des équilibres produits par des systèmes apprenants.

Cette formulation remplace la revendication de primauté de la v1.0 (« premier framework »), qui était **indéfendable** devant un comité scientifique. Elle est :

— **Vérifiable** — elle décrit une contribution positive

— **Explicite** — elle nomme la lacune comblée

— **Positionnée** — elle situe AEXIA™ comme complémentaire des référentiels existants

### 1.3 Attributions et paternité

| Élément | Auteur | Statut |
|---|---|---|
| **Architecture à 6 piliers** | Mohamadou SIDIBE | Synthèse originale de 18 référentiels |
| **Modèle de maturité organisationnelle (axe O)** | Mohamadou SIDIBE, d'après CMMI et DCAM | Adaptation au contexte XAI |
| **Modèle de maturité par système (axe S)** | Mohamadou SIDIBE, d'après Lavin et al. (2022) | Adaptation au contexte réglementaire |
| **DCME** | Mohamadou SIDIBE | **Contribution originale** |
| **ECS** | Mohamadou SIDIBE | **Contribution originale** |
| **RAD** | Mohamadou SIDIBE | **Contribution originale** |
| **AEXIA™ Card** | Mohamadou SIDIBE, d'après TRL Cards (Lavin et al.) | Adaptation opérationnelle |
| **Matrice de croisement O×S** | Mohamadou SIDIBE | **Contribution originale** |
| **Mécanismes de robustesse** | Mohamadou SIDIBE, d'après NASA TRL et MLTRL | Adaptation |

## 2 Architecture à double axe

### 2.1 Vue d'ensemble : la correction structurante

La version 1.0 mesurait une seule chose : la maturité de l'organisation. C'est nécessaire mais **insuffisant**. Une organisation mature peut exploiter un système immature ; une organisation immature peut héberger un système techniquement irréprochable. Ce sont **deux propriétés distinctes**, et les confondre produit des diagnostics faux.

AEXIA™ s'organise autour de **deux axes complémentaires** :

— **Axe O (Organisationnel)** : maturité de l'organisation à gouverner l'IA explicable. Évalué une à deux fois par an.

— **Axe S (Système)** : maturité d'un système d'IA donné. Réévalué à chaque passage de porte et à chaque incident.

**Principe directeur** : AEXIA™-O répond à « notre organisation sait-elle gouverner l'IA explicable ? ». AEXIA™-S répond à « ce système précis est-il prêt, et pour quel environnement ? ». Leur croisement détermine ce que l'organisation a le droit de déployer et avec quels contrôles.

### 2.2 Axe O : maturité organisationnelle (AEXIA™-O)

Six piliers évalués sur 6 niveaux (N0 à N5). Le **niveau AEXIA™-O publié** est celui du **pilier le plus faible** — règle du maillon faible empruntée à l'ingénierie système NASA.

| # | Pilier | Domaine | Référentiels sources |
|---|---|---|---|
| F | **Fondements** | Bases mathématiques et théoriques (SHAP, LIME, DCME) | DAMA-DMBOK · ISO 8000 · DCAM |
| A | **Architecture** | Infrastructure technique et organisationnelle XAI | TOGAF · DAMA-DMBOK · DCAM · MLflow |
| G | **Gouvernance** | Rôles, responsabilités, politiques, contrôle | COBIT · DGI · ISO/IEC 38505 · 38507 |
| C | **Conformité** | Réglementation, éthique, audit | NIST AI RMF · EU AI Act · OECD · UNESCO · RGPD |
| O | **Opérations** | Excellence opérationnelle, gestion de projet | ITIL v4 · Agile · PRINCE2 · Lean/Six Sigma · CMMI |
| M | **Mesure & Amélioration** | Évaluation, mesure, amélioration continue | CMMI · DCAM · ISO 8000 · Six Sigma |

### 2.2.1 Échelle de maturité organisationnelle

| Niveau | Nom | Signal caractéristique |
|---|---|---|
| N0 | **Inexistant** | Aucune pratique XAI. Boîte noire totale. |
| N1 | **Initial** | Pratiques ad hoc, réactives, non documentées. |
| N2 | **Défini** | Politique XAI rédigée, méthodes sélectionnées, rôles désignés. |
| N3 | **Géré** | KPIs suivis, audit interne régulier, conformité AI Act avancée. |
| N4 | **Avancé** | DCME déployée, ECS mesurée, RAD calculée. Automatisation. |
| N5 | **Excellence** | Référence internationale, contribution aux normes ISO. |

**Maillon faible** : avec une pondération simple (F :20%, A :15%, G :20%, C :20%, O :15%, M :10%), une organisation dont le pilier Conformité est à N0 mais tous les autres à N4 obtiendrait un score de 3,2 — affichage « Géré » alors qu'elle est en **exposition juridique directe**. La règle du maillon faible affiche **N0** et rend l'exposition visible immédiatement.

## 2.3 Axe S : maturité par système (AEXIA™-S)

Chaque système d'IA déployé reçoit son propre niveau de 0 à 9, réévalué à chaque passage de porte et à chaque incident. Cet axe est **aligné sur les MLTRL** (Lavin et al., *Nature Communications* 13, 6039, 2022).

| Niv. | Étape | Contenu | Environnement / Exigence AEXIA™ |
|---|---|---|---|
| S0 | **Premiers principes** | Idée, revue de littérature, bases mathématiques, compréhension des données. | Aucune. Pilier F seul mobilisé. |
| S1 | **Recherche orientée** | Expérimentations exploratoires sur données échantillonnées ou synthétiques. | Laboratoire. Traçabilité des hypothèses exigée. |
| S2 | **Preuve de principe** | Le concept fonctionne sur un cas restreint. Limites documentées. | Laboratoire. Première fiche de risque AI Act. |
| S3 | **Développement système** | Code structuré, pipeline reproductible, jeu de référence constitué. | Laboratoire. Revue de data readiness obligatoire. |
| S4 | **Preuve de concept** | Validation sur données réelles en environnement contrôlé. Méthode XAI sélectionnée. | Représentatif. Matrice de sélection appliquée. |
| S5 | **Capacité démontrée** | Le système constitue une capacité métier identifiable. | Représentatif. **Porte critique : entrée dans la vallée de la mort.** |
| S6 | **Développement applicatif** | Qualité logicielle de production. Explicabilité intégrée par conception. | Représentatif. Store des explications opérationnel. |
| S7 | **Intégration** | Intégration aux systèmes de production. Jeu de référence figé. | Opérationnel restreint. Bac à sable réglementaire si applicable. |
| S8 | **Qualifié** | Démontré dans sa forme finale. Dossier de conformité complet. | Opérationnel. Décision formelle de mise en service par le DGC. |
| S9 | **En service surveillé** | Exploitation. L'enjeu bascule vers la maintenance. | Opérationnel. Surveillance après commercialisation (AI Act art. 72). |

### 2.4 Matrice de croisement AEXIA™-O × AEXIA™-S

| **Maturité Org.** | Systèmes S0-S5 | Systèmes S6-S7 | Systèmes S8-S9 |
|---|---|---|---|
| **N0-N1** | Toléré : phase exploratoire. | **INTERDIT** : l'organisation n'a pas les contrôles. | **ALERTE MAJEURE** : système en production sans gouvernance. |
| **N2** | Toléré avec traçabilité. | Autorisé sous condition : porte franchie en comité. | Autorisé pour risque limité uniquement. Haut risque : NON. |
| **N3** | Normal. | Normal, porte franchie sur preuve. | Autorisé, y compris haut risque, sous surveillance mesurée. |
| **N4-N5** | Normal. | Normal, automatisé. | Normal, avec rétrogradation automatisée sur dérive. |

## 3 Les 4 mécanismes de robustesse

Ces mécanismes distinguent un framework **opérationnel** d'un référentiel **déclaratif**. Trois sont empruntés à l'ingénierie système (NASA, MLTRL) ; le quatrième est spécifique à l'IA apprenante.

### 3.1 Mécanisme 1 : Règle du maillon faible

Le niveau AEXIA™-O publié est celui du **pilier le plus faible**, jamais la moyenne pondérée. Le niveau AEXIA™-S d'un système est celui de son **composant le moins mûr**. Emprunté directement au TRL de la NASA.

### 3.2 Mécanisme 2 : Portes probantes

Aucun passage de niveau ne s'obtient par déclaration. Chaque transition exige un **jeu fermé d'artefacts**, examinés en revue.

| **Porte** | Artefacts exigés | *Instance décisionnaire* |
|---|---|---|
| **S2 → S3** | Fiche de risque AI Act, classification, revue de data readiness. | *Data Owner métier + Data Steward XAI* |
| **S5 → S6** | Justification de la méthode XAI, seuils de qualité, quantification des risques. | ***DGC (porte critique)*** |
| **S7 → S8** | Dossier de conformité complet, jeu de référence figé, procédure de surveillance. | *DGC + DPO + décision formelle* |
| **S8 → S9** | Pipelines de surveillance actifs, seuils de dérive, procédure de rétrogradation testée. | *DGC + DSI* |

### 3.3 Mécanisme 3 : Rétrogradation (spécifique à l'IA)

Une fusée qualifiée reste qualifiée. Un système d'IA, non. Lavin et al. documentent explicitement ce phénomène : les décalages de distribution de données d'un contexte de déploiement à l'autre affectent significativement les calibrations.

| **Déclencheur** | Rétrogradation | Obligation |
|---|---|---|
| **Dérive de données ou de concept au-delà du seuil** | S9 → S6 | Réexamen méthode XAI, recalibrage, nouvelle porte S7→S8. |
| **Incident d'explicabilité** | S9 → S7 | Analyse de cause racine, correction, revue DGC. |
| **Changement significatif de la population d'usagers** | S9 → S6 | Revue de data readiness, contrôle d'équité, réexamen conformité. |
| **Évolution réglementaire applicable** | S9 → S8 | Mise à jour du dossier de conformité, nouvelle décision formelle. |
| **Modification du modèle (réentraînement)** | S9 → S7 | Comparaison au jeu de référence, validation des explications. |

### 3.4 Mécanisme 4 : Proportionnalité au risque

Appliquer l'intégralité d'AEXIA™ à un modèle de recommandation interne à faible enjeu est un **gaspillage**.

| Catégorie | Portes obligatoires | Fréquence | Profondeur XAI |
|---|---|---|---|
| **Risque inacceptable (art. 5)** | Sans objet — déploiement interdit | — | — |
| **Haut risque (annexes I et III)** | Toutes (S2→S3, S5→S6, S7→S8, S8→S9) | Trimestrielle + incident | Complète : explication individuelle |
| **Risque limité (art. 50)** | S5→S6 et S7→S8 | Semestrielle | Explication globale |
| **Risque minimal** | S7→S8 uniquement, allégée | Annuelle | Documentation des variables |

# 4 Les 6 piliers AEXIA™ en détail

## 4.1 Pilier F : Fondements

*Bases mathématiques et théoriques (SHAP, LIME, DCME)*
**Frameworks sources** : DAMA-DMBOK · ISO 8000 · DCAM

| Composante | Livrables |
|---|---|
| **Glossaire XAI** | Définitions normalisées : explicabilité, interprétabilité, transparence, valeur de Shapley, LIME, DCME. |
| **Catalogue des méthodes** | Inventaire structuré : SHAP, LIME, ANCHORS, DiCE, Integrated Gradients, DCME, avec pré-requis et limites. |
| **Matrice de sélection** | Guide décisionnel : pour chaque type de modèle et chaque contexte, quelle méthode XAI utiliser. |
| **Standards qualité des explications** | Critères : fidélité, robustesse, lisibilité, reproductibilité, défendabilité réglementaire. |
| **Formation des équipes** | Modules par profil : CDO, Data Scientist, Data Steward, DPO, Manager métier. |

## 4.2 Pilier A : Architecture

*Infrastructure technique et organisationnelle XAI*
**Frameworks sources** : TOGAF · DAMA-DMBOK · DCAM · MLflow

| Couche | Composantes | *Intégration* |
|---|---|---|
| **Données** | Data catalog augmenté XAI : métadonnées, distributions, corrélations, lignée. | *DAMA-DMBOK · ISO 8000 · DCAM* |
| **Modèles** | Model Registry : version, algorithme, métriques, méthode XAI, niveau de risque. | *TOGAF · MLflow / Kubeflow* |
| **Explications** | Store des explications : SHAP, LIME, DCME, ECS, RAD. API d'accès. | *COBIT · ITIL* |
| **Gouvernance** | Tableau de bord XAI : KPIs, alertes, rapport DGC automatique. | *COBIT · DGI · ISO 38505* |
| **Intégration** | Pipeline MLOps augmenté XAI. Gate AEXIA™ avant mise en production. | *ITIL · Agile · CMMI* |

## 4.3 Pilier G : Gouvernance

*Rôles, responsabilités, politiques et contrôle*
**Frameworks sources** : COBIT · DGI · ISO/IEC 38505 · ISO/IEC 38507

| Rôle | Responsabilités XAI | *Autorité* | Fréquence |
|---|---|---|---|
| **CDO** | Mandater la politique AEXIA™. Valider le Score. Reporter au COMEX. | *Élevée* | Semestrielle |
| **DSI** | Sélectionner les outils XAI. Intégrer aux pipelines. | *Élevée* | Continue |
| **DPO** | Valider la conformité RGPD art. 22. Arbitrer les demandes. | *Réglementaire* | Continue |
| **Data Owner** | Valider les explications de son périmètre. Approuver les changements. | *Moyenne* | Mensuelle |
| **Data Steward XAI** | Calculer et archiver les explications. Surveiller la qualité. | *Opérationnelle* | Quotidienne |
| **DGC** | Valider les évolutions. Arbitrer les conflits. Valider le plan. | *Collective* | Trimestrielle |

## 4.4 Pilier C : Conformité

*Réglementation, éthique et audit*
**Frameworks sources** : NIST AI RMF · EU AI Act · OECD · UNESCO · RGPD

| Cadre | Obligation XAI clé | Deadline | Couverture AEXIA™ |
|---|---|---|---|
| **EU AI Act** | Transparence et explicabilité pour systèmes à haut risque | 2 déc. 2027 / 2 août 2028 | Piliers C + G |
| **RGPD art. 22** | Droit à l'explication pour décisions automatisées | En vigueur | Piliers F + O |
| **NIST AI RMF 1.0** | Cycle 4M · 7 caractéristiques | Référence | Piliers C + M |
| **OECD AI Principles** | 5 principes directeurs | Référence | Piliers G + F + C |
| **UNESCO AI Ethics** | Dignité, vie privée, non-discrimination | Référence | Piliers C + G |

## 4.5 Pilier O : Opérations

*Excellence opérationnelle et gestion de projet*
**Frameworks sources** : ITIL v4 · Agile · PRINCE2 · Lean/Six Sigma · CMMI

| Pratique | Description | *Source* | Fréquence |
|---|---|---|---|
| **Sprint XAI** | Cycle de 2 semaines dédié à l'amélioration XAI. | *Agile/Scrum* | Bi-mensuel |
| **Runbook AEXIA™** | Procédures standardisées : client, régulateur, incident. | *ITIL v4* | Continue |
| **SLA d'explication** | 24 h client · 48 h régulateur · 5 min alerte système. | *ITIL v4* | Par défaut |
| **Kanban AEXIA™** | To Explain · In Progress · Done · Escalated. | *Kanban* | Quotidien |
| **Lean AEXIA™** | Élimination des gaspillages. | *Lean/Six Sigma* | Trimestriel |
| **PRINCE2 XAI** | Déploiement grande échelle : Business Case, jalons. | *PRINCE2* | Par projet |

### 4.6 Pilier M : Mesure & Amélioration

*Évaluation, mesure et amélioration continue*
**Frameworks sources** : CMMI · DCAM · ISO 8000 · Six Sigma

| KPI | Définition | Calcul | Cible N3 |
|---|---|---|---|
| **Niveau AEXIA™-O** | Niveau du pilier le plus faible. | min(piliers) | $\geq$ N3 |
| **Taux de couverture XAI** | % modèles avec explication validée. | Modèles expliqués / Total | $\geq 80\ \%$ |
| **Délai moyen d'explication** | Temps demande $\rightarrow$ livraison validée. | Moyenne | $< 24$ h |
| **Score de qualité des explications** | Composite fidélité + robustesse + lisibilité. | 0-5 | $\geq 4.0$ |
| **Nombre d'incidents XAI** | Incidents liés à explication manquante. | Comptage mensuel | $< 2$/mois |

## 5 Le noyau original : DCME, ECS et RAD

**Statut de cette section**

**DCME, ECS et RAD sont les apports intellectuels propres de Mohamadou SIDIBE.** Ils constituent le seul élément d'AEXIA™ qu'aucun autre framework ne peut revendiquer. La présente section les formalise selon les **7 exigences d'un comité de lecture ou d'un groupe de normalisation ISO/IEC JTC 1/SC 42**.

### 5.1 DCME : Dynamic Causal Multi-scale Explanation

#### 5.1.1 Définition formelle

**DCME** est une méthode d'explication qui décompose la prédiction d'un modèle en **contributions causales** organisées sur **plusieurs échelles d'analyse** (macro, méso, micro), en distinguant les **effets directs** des **effets médiés** par des variables intermédiaires.

#### 5.1.2 Formulation mathématique

Pour une prédiction $f(x) = \hat{y}$, la décomposition DCME s'écrit :

$$\hat{y} = \phi_0 + \sum_{s \in \mathcal{S}} \sum_{i \in \mathcal{F}_s} \phi_i^{(s)} + \sum_{(i,j) \in \mathcal{E}} \psi_{ij} \tag{1}$$

où :

— $\phi_0$ est la prédiction de base (baseline)

— $\mathcal{S} = \{s_1, \ldots, s_K\}$ est l'ensemble des échelles (macro, méso, micro)

— $\mathcal{F}_s$ est l'ensemble des variables à l'échelle $s$

— $\phi_i^{(s)}$ est la contribution directe de la variable $i$ à l'échelle $s$

— $\mathcal{E}$ est l'ensemble des effets causaux médiés identifiés dans le graphe causal

— $\psi_{ij}$ est l'effet médié de la variable $i$ sur la variable $j$

**Contrainte d'additivité multi-échelle** :

$$\sum_{s} \sum_{i \in \mathcal{F}_s} \phi_i^{(s)} + \sum_{(i,j) \in \mathcal{E}} \psi_{ij} = \hat{y} - \phi_0 \tag{2}$$

### 5.1.3 Conditions d'application

— Modèle différentiable ou approximable

— Graphe causal connu ou inférable (expertise métier + tests de causalité)

— Données stationnaires sur la fenêtre d'analyse

— Absence de variables latentes non observables majeures

### 5.1.4 Limites connues

— **Complexité computationnelle** : $O(K \cdot |\mathcal{F}|^2)$

— **Dépendance au graphe causal** : un graphe mal spécifié produit des contributions biaisées

— **Interprétabilité** : plus riche mais plus difficile à lire qu'un SHAP simple

— **Ne traite pas** les variables latentes ni les confusions non observées

### 5.1.5 Positionnement vs existant

| Méthode | Échelle | Causalité | Médiation | Complexité |
|---|---|---|---|---|
| **SHAP** | Unique (additive) | Non | Non | $O(2^n)$ exact |
| **LIME** | Locale (linéaire) | Non | Non | $O(n)$ par instance |
| **Integrated Gradients** | Unique (gradient) | Non | Non | $O(n)$ par instance |
| **DCME** | **Multi-échelle** | **Oui** | **Oui** | $O(K \cdot \|\mathcal{F}\|^2)$ |

### 5.1.6 Protocole de mesure

1. Construction du graphe causal (expertise métier + tests Granger, PC algorithm)
2. Définition des échelles (macro, méso, micro)
3. Estimation des contributions directes par méthode d'attribution adaptée
4. Estimation des effets médiés par propagation sur le graphe (Pearl, 2009)
5. Vérification de l'additivité
6. Validation croisée avec SHAP sur les variables non médiées
7. Tests de robustesse (variation des échelles, du graphe, des données)

#### 5.1.7 Cas d'application démontré

Application sur les jeux de données **COMPAS** (récidive) et **German Credit** (scoring crédit).

### 5.2 ECS : Explanation Consistency Score

#### 5.2.1 Définition formelle

**ECS** est une métrique évaluant la **stabilité d'une explication** lorsqu'elle est recalculée sur des échantillons voisins ou sur des perturbations contrôlées.

#### 5.2.2 Formulation mathématique

Soit $\phi(f, x)$ l'explication du modèle $f$ sur l'instance $x$. Soit $\mathcal{N}_\epsilon(x)$ un voisinage de rayon $\epsilon$.

$$\text{ECS}(f, x, \epsilon) = 1 - \frac{1}{N} \sum_{k=1}^{N} \frac{\|\phi(f, x) - \phi(f, x_k)\|_1}{\|\phi(f, x)\|_1 + \delta} \tag{3}$$

où $x_k \sim \mathcal{N}_\epsilon(x)$ et $\delta > 0$ est une constante de régularisation.
**Propriétés** : ECS $\in [0, 1]$, ECS $= 1$ pour une explication parfaitement stable.
**Version agrégée** :

$$\text{ECS}_{model}(f, \mathcal{D}, \epsilon) = \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} \text{ECS}(f, x, \epsilon) \tag{4}$$

#### 5.2.3 Conditions d'application

— Méthode d'explication déterministe ou à variance contrôlée
— Échantillonnage bien défini du voisinage
— Normalisation des variables avant calcul
— Choix justifié de $\epsilon$ (recommandé : 5 % de l'écart-type par variable)

#### 5.2.4 Positionnement vs existant

| Métrique | Mesure | Stabilité | Fidélité |
|---|---|---|---|
| **Fidelity (LIME)** | Fidélité locale | Non | Oui |
| **Robustness (Alvarez-Melis & Jaakkola, 2018)** | Stabilité sous bruit | Oui | Non |
| **Sensitivity (Yeh et al., 2019)** | Variation de l'explication | Oui | Non |
| **ECS** | **Stabilité normalisée** | **Oui** | Non |

### 5.3 RAD : Responsibility Algorithmic Debt

#### 5.3.1 Définition formelle

**RAD** est un indicateur cumulatif mesurant l'**écart entre la maturité attendue** d'un système et sa **maturité effective**, pondéré par sa **criticité réglementaire** au sens de l'AI Act.

#### 5.3.2 Formulation mathématique

**RAD par système** :

$$\mathrm{RAD}_i(T) = \sum_{t=1}^{T} \alpha_t \cdot \max\left(0, S^{(i)}_{attendu}(t) - S^{(i)}_{effectif}(t)\right) \cdot \beta_i \tag{5}$$

où :

— $T$ = horizon temporel (mois)

— $\alpha_t = e^{-\lambda(T-t)}$ = facteur de récence ($\lambda \approx 0.1$/mois)

— $S^{(i)}_{attendu}(t)$ = niveau AEXIA™-S cible du système $i$

— $S^{(i)}_{effectif}(t)$ = niveau effectif du système $i$

— $\beta_i \in \{1, 2, 3, 4\}$ = coefficient de criticité AI Act

**RAD portefeuille** :

$$\mathrm{RAD}_{portfolio}(T) = \sum_{i=1}^{N} \mathrm{RAD}_i(T) \tag{6}$$

**RAD normalisé** :

$$\mathrm{RAD}_{norm}(T) = \frac{\mathrm{RAD}_{portfolio}(T)}{N \cdot \beta_{max} \cdot S_{max}} \tag{7}$$

#### 5.3.3 Interprétation

— $\mathrm{RAD}_{norm} < 0.10$ : organisation alignée

— $0.10 \leq \mathrm{RAD}_{norm} < 0.25$ : écarts modérés, plan d'amélioration

— $\mathrm{RAD}_{norm} \geq 0.25$ : dette critique, arbitrage budgétaire nécessaire

#### 5.3.4 Positionnement vs existant

| Concept | Domaine | Nature |
|---|---|---|
| **Technical Debt (Cunningham, 1992)** | Développement logiciel | Dette de code |
| **Data Debt** | Gouvernance des données | Dette de qualité |
| **Model Debt** | MLOps | Dette de maintenance |
| **AI Risk Score (NIST AI RMF)** | Gestion des risques | Risque instantané |
| **RAD** | **Responsabilité algorithmique** | **Dette cumulée (original)** |

### 5.4 Articulation des trois concepts avec les 6 piliers

| Concept | Pilier principal | Niveau requis | Usage opérationnel |
|---|---|---|---|
| **DCME** | F (Fondements) | N4 — Avancé | Explication causale multi-échelle |
| **ECS** | M (Mesure) | N4 — Avancé | Évaluation de la stabilité des explications |
| **RAD** | G (Gouvernance) | N4 — Avancé | Pilotage de la dette de responsabilité algorithmique |

# 6 La fiche système AEXIA™ Card

Inspirée des **TRL Cards** de Lavin et al. (2022), la fiche système est l'artefact qui rend AEXIA™ tangible au quotidien. **C'est le document qu'un régulateur demandera en premier.**

| Rubrique | Contenu |
|---|---|
| **Identification** | Nom du système, propriétaire métier, date de mise en service, version du modèle. |
| **Classification AI Act** | Catégorie de risque, annexe applicable, justification, date de dernière révision. |
| **Niveau AEXIA™-S** | Niveau actuel (S0-S9), date d'obtention, instance ayant statué, historique. |
| **Maillon faible** | Composant déterminant le niveau actuel, plan de remédiation. |
| **Méthode XAI** | Méthode retenue (SHAP/LIME/DCME), justification, seuils de qualité (ECS cible), SLA (RAD). |
| **Données** | Niveau de data readiness, jeu de référence, dernière revue, lignée. |
| **Surveillance** | Indicateurs de dérive, seuils de rétrogradation, fréquence, dernier contrôle. |
| **Conformité** | Pièces du dossier, date du dernier audit, écarts ouverts, échéance AI Act. |

**Conseil de diffusion** : publiez librement le **gabarit** de la fiche AEXIA™ Card (CSV ou XLSX). Un modèle de fiche téléchargeable fera davantage pour la diffusion d'AEXIA™ que le document conceptuel. C'est ainsi que CMMI et DCAM se sont diffusés.

# 7 Cycle de vie AEXIA™

| Phase | Nom | Objectif | Durée | Outputs |
|---|---|---|---|---|
| **MAP** | **Cartographier** | Inventorier tous les modèles d'IA, scorer leur risque, évaluer la maturité initiale. | 2-4 sem. | Inventaire · Scoring · Score initial |
| **DEFINE** | **Définir** | Définir la politique, les rôles RACI, les méthodes XAI et seuils de conformité. | 4-8 sem. | Charte · RACI · Sélection SHAP/LIME/DCME |
| **BUILD** | **Construire** | Déployer les outils XAI, intégrer dans MLOps, former les équipes. | 2-6 mois | Pipeline XAI · Data catalog · Dashboard |
| **GOVERN** | **Gouverner** | Mettre en place les contrôles, les portes probantes et procédures d'audit. | Continu | Audit trail · Rapport DGC · Conformité |
| **OPERATE** | **Opérer** | Gérer les explications en production : incidents, SLA, RAD. | Continu | Runbook · SLA · Scripts · Tickets |
| **IMPROVE** | **Améliorer** | Évaluer la maturité, identifier les écarts, lancer les plans. | Trimestriel | Score mis à jour · Roadmap · Rapport COMEX |

# 8 Modèle de maturité et système de notation

## 8.1 Modèle de maturité organisationnelle — 6 piliers × 5 niveaux

| Pilier | N1 — Initial | N2 — Défini | N3 — Géré | N4 — Avancé | N5 — Excellence |
|---|---|---|---|---|---|
| **F** | SHAP/LIME ad hoc | Méthode sélectionnée | Benchmark, glossaire | DCME, ECS mesurée | Contribution normes |
| **A** | Outils manuels | Pipeline MLOps | Data catalog XAI | Multi-échelle auto | Architecture publiée |
| **G** | Rôle informel | Charte, RACI, DGC | DGC trimestriel | Gouvernance systémique | Référent international |
| **C** | Notions parcellaires | Registre risques | Audit annuel | Conformité auto | Travaux normatifs EU |
| **O** | Explications à la demande | Sprints, runbook | SLA, KPIs | ITIL complet | Centre d'excellence |
| **M** | Auto-évaluation | Score 1/an | Dashboard trimestriel | Prédiction écarts | Benchmark et publication |

## 8.2 Système de notation révisé — Le triptyque AEXIA™

La notation AEXIA™ v3.0 publie **trois valeurs**, jamais une seule.

| Indicateur | Définition | Usage |
|---|---|---|
| **Niveau AEXIA™-O** | Niveau du pilier le plus faible. | Valeur publiée en externe et au COMEX. |
| **Profil AEXIA™-O** | Niveau des 6 piliers, présenté en radar. | Pilotage interne : où investir. |
| **Distribution AEXIA™-S** | Répartition du parc de systèmes par niveau S0-S9. | Pilotage opérationnel et arbitrage. |

## 9 Conformité réglementaire

**Recommandation de forme** : dater explicitement cette section (« état du droit au [date] ») et prévoir une **revue semestrielle**.

| Disposition | Contenu exact | Couverture AEXIA™ |
|---|---|---|
| **Calendrier annexe III** | Obligations pour systèmes à haut risque autonomes : **2 décembre 2027**, après report par le règlement Digital Omnibus (UE 2026/1744). | Portes S7→S8 et S8→S9, pilier C |
| **Calendrier annexe I** | Systèmes à haut risque intégrés à des produits réglementés : **2 août 2028**. | Idem, échéance propre |
| **Sanctions — pratiques interdites (art. 5)** | Jusqu'à **35 M€ ou 7 %** du CA annuel mondial. | Mécanisme 4 : risque inacceptable |
| **Sanctions — non-conformité haut risque** | Jusqu'à **15 M€ ou 3 %** du CA annuel mondial. | Piliers C et G, portes probantes |
| **Sanctions — informations inexactes** | Jusqu'à **7,5 M€ ou 1 %** du CA annuel mondial. | Pilier C : audit trail |
| **PME et jeunes entreprises** | Plafonds proportionnés : le moindre entre % et montant fixe. | Mécanisme 4 : proportionnalité |
| **Bacs à sable réglementaires (art. 57-59)** | Au moins un par État membre. | Axe S : environnement du niveau 7 |
| **Surveillance après mise sur le marché (art. 72)** | Obligation de surveillance continue. | Mécanisme 3 : rétrogradation, S9 |
| **RGPD art. 22** | Droit à l'explication pour décisions automatisées. | Piliers F et O |

 DOI: 10.5281/zenodo.23126471

## 10 Mapping avec les 18 frameworks sources

| Framework | Contribution principale à AEXIA™ | *Pilier(s)* |
|---|---|---|
| **DAMA-DMBOK** | Rôles Data Owner, Data Steward, DGC, data catalog, glossaire. | *F · A · G* |
| **DCAM** | Évaluation des capacités de gestion des données, scoring. | *F · M* |
| **ISO 8000** | Qualité des données maîtresses. | *F · A* |
| **CMMI** | Modèle de maturité à 5 niveaux, amélioration continue. | *M · O* |
| **COBIT 2019** | Structure de gouvernance IT, objectifs de contrôle, métriques. | *G · C · M* |
| **ISO/IEC 38505** | Gouvernance des données : principes, responsabilités. | *G* |
| **DGI Framework** | Charte de gouvernance des données, comités. | *G* |
| **ISO/IEC 38507** | Gouvernance des systèmes d'IA. | *G · C* |
| **NIST AI RMF 1.0** | Cycle 4M, 7 caractéristiques IA de confiance. | *C · M* |
| **OECD AI Principles** | 5 principes IA directeurs. | *C* |
| **EU AI Act 2024/1689** | Obligations légales systèmes à haut risque. | *C* |
| **UNESCO AI Ethics** | Recommandation 2021 : dignité, vie privée, non-discrimination. | *C* |
| **AIPGF** | Gouvernance des projets IA : cas d'usage, parties prenantes. | *O · G* |
| **PRINCE2** | Gestion de projet structurée. | *O* |
| **Agile / Scrum / Kanban** | Sprints XAI, Kanban, rétrospectives. | *O* |
| **Lean / Six Sigma** | Réduction des défectueux dans la production d'explications. | *O · M* |
| **ITIL v4** | Gestion des incidents XAI, SLA, knowledge base. | *O* |
| **TOGAF ADM** | Architecture de référence XAI en couches. | *A* |
| **MLTRL — Lavin et al. 2022** | 9 niveaux de maturité des systèmes ML. **Fondement de l'axe S.** | *A · M* |

## 11 Feuille de route d'implémentation

| Horizon | Mois | Priorités | Cible O | Cible S |
|---|---|---|---|---|
| **Court terme** | M0-M3 | Inventaire, classification AI Act, première fiche AEXIA™ Card, désignation des rôles. | N0 → N1 | Tous positionnés |
| **Moyen terme** | M3-M12 | Politique, portes S5→S6 et S7→S8, store des explications, pipelines de surveillance. | N1 → N2 | Aucun haut risque > S7 sans porte |
| **Long terme 1** | M12-M24 | Audit interne, rétrogradation testée, automatisation, formalisation DCME/ECS/RAD. | N2 → N3 | Distribution stabilisée |
| **Long terme 2** | M24-M36 | Conformité Annexe III avant 2 déc. 2027, normalisation ISO, publication. | N3 → N4 | Rétrogradation automatisée |

## Références


1. Lavin, A., Gilligan-Lee, C. M., Visnjic, A., et al. (2022). Technology readiness levels for machine learning systems. *Nature Communications*, 13(1), 6039. `https://doi.org/10.1038/s41467-022-33128-9`
2. Règlement (UE) 2024/1689 du Parlement européen et du Conseil établissant des règles harmonisées concernant l'intelligence artificielle (AI Act).
3. Règlement (UE) 2026/1744 dit « Digital Omnibus », reportant les échéances applicables aux systèmes à haut risque (Annexe III : 2 décembre 2027).
4. NIST AI Risk Management Framework 1.0 (2023). National Institute of Standards and Technology.
5. ISO/IEC 42001 :2023 — Information technology — Artificial intelligence — Management system.
6. Mankins, J. C. (1995). *Technology Readiness Levels : A White Paper*. NASA Office of Space Access and Technology.
7. Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS*.
8. Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why Should I Trust You ?" : Explaining the Predictions of Any Classifier. *KDD*.
9. Alvarez-Melis, D., & Jaakkola, T. S. (2018). On the Robustness of Interpretability Methods. *ICML Workshop on Human Interpretability*.
10. Yeh, C.-K., Hsieh, C.-Y., Suggala, A., Inouye, D. I., & Ravikumar, P. (2019). On the (In)fidelity and Sensitivity of Explanations. *NeurIPS*.
11. Pearl, J. (2009). *Causality : Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.
12. Cunningham, W. (1992). The WyCash Portfolio Management System. *OOPSLA*.
13. OECD (2019). Recommendation of the Council on Artificial Intelligence. OECD/LEGAL/0449.
14. UNESCO (2021). Recommandation sur l'éthique de l'intelligence artificielle. Adoptée le 23 novembre 2021.
15. DAMA International (2017). *DAMA-DMBOK : Data Management Body of Knowledge* (2nd ed.). Technics Publications.
16. ISACA (2018). *COBIT 2019 Framework : Introduction and Methodology*.
17. CMMI Institute (2018). *CMMI for Development, Version 2.0*.
18. The Open Group (2018). *TOGAF Standard, Version 9.2*.
19. EDM Council. *DCAM — Data Management Capability Assessment Model*.
20. ISO/IEC 38505-1 :2017 — Information technology — Governance of IT — Part 1.
21. SIDIBE, Mohamadou (2026). *AEXIA™ Framework — Accountable, Ethical, eXplainable, Interpretable, Auditable AI Governance Framework*, Version 3.0. IA BIAIS INITIATIVE. DOI : `10.5281/zenodo.23126471`.

# AEXIA™ Framework — Version 3.0 — Octobre 2026

**Mohamadou SIDIBE**
Chief Data Officer, FGV
Fondateur, IA BIAIS INITIATIVE
contact@ia-biais-initiative.org

*Accountable · Ethical · eXplainable · Interpretable · Auditable AI Governance Framework*

DOI : 10.5281/zenodo.23126471